TEL211

Disponibilidad y Rendimiento de Sistemas TIC

Cadenas de Markov en tiempo continuo y disponibilidad

Patricio Olivares R.
Universidad Técnica Federico Santa María

Continuidad

Anteriormente, observamos un sistema reparable en pasos de duración fija. Calculamos su distribución futura y sumamos los estados que prestan servicio.

Ahora queremos seguirlo mientras los eventos ocurren en cualquier instante:

$$\text{operativo} \to \text{caído} \to \text{operativo}.$$

> Conservamos los estados y el criterio de servicio. Cambiamos la forma de describir el tiempo y las transiciones.

Ruta de esta unidad

- ¿Cómo construir un modelo con tasas y permanencias?
- ¿Cómo evoluciona la disponibilidad de un sistema reparable?
- ¿Cómo incorporar varios componentes y una política de reparación?

Primero construiremos la matriz Q. Después obtendremos probabilidades y métricas a partir del mismo modelo.

¿Qué es una CTMC?

Una **cadena de Markov en tiempo continuo**, abreviada CTMC, tiene estados discretos y un índice temporal continuo:

$$\{X(t) : t \geq 0\}, \qquad X(t) \in \mathcal{S}.$$

Siendo $\mathcal{S}$ el conjunto de estados.

Conocido el estado presente, el pasado no agrega información para describir la evolución futura.

Por ejemplo, $X(t)$ puede indicar si un enlace está operativo o caído, o cuántos servidores funcionan en el instante t.

Tiempo continuo y homogeneidad

Una falla puede ocurrir a los 2.4 minutos y una reparación terminar a los 5.7 minutos. No necesitamos redondear esos eventos a pasos enteros.

En esta unidad usaremos **CTMC homogéneas**: sus tasas no cambian con el tiempo calendario.

> La propiedad de Markov especifica qué información contiene el estado. La homogeneidad especifica que las reglas de evolución no cambian con el tiempo.

De probabilidades a tasas

En una DTMC, p_{ij} es una probabilidad por paso. En una CTMC, q_{ij} es una tasa de cambio desde i hacia j, para $i \neq j$.

En un intervalo pequeño h:

$$P(X(t+h) = j \mid X(t) = i) = q_{ij}h + o(h).$$

El término $o(h)$ reúne efectos cuya importancia relativa desaparece al hacer h muy pequeño.

Las tasas tienen unidad de tiempo inverso. Pueden superar 1 y no son probabilidades.

Ejemplo: interpretar una tasa

Suponga que un enlace operativo falla con tasa

$$\lambda = 0.02\ \mathrm{h}^{-1}.$$

En un intervalo de $h = 0.1\ \mathrm{h}$, la probabilidad de sufrir una primera falla es aproximadamente

$$\lambda h = 0.002.$$

Si el tiempo hasta la primera falla es exponencial, la probabilidad exacta es $1 - e^{-\lambda h}$. En el ejemplo, $1 - e^{-0.002} \approx 0.001998$, muy cercano a 0.002.

Con λ fija, λh aproxima un crecimiento lineal de la probabilidad al aumentar h, solo para intervalos pequeños. La tasa no cambia con el tiempo.

Permanencia en un estado

Para $i \neq j$, q_{ij} es la tasa de transición desde i hacia j: salida de i y entrada a j. La tasa total de salida desde i suma las tasas hacia todos los demás estados:

$$\nu_i = \sum_{j \neq i} q_{ij}.$$

Si el tiempo de permanencia S_i en i es exponencial, su tasa es la tasa total de salida $\nu_i > 0$:

$$P(S_i > t) = e^{-\nu_i t}, \qquad E[S_i] = \frac{1}{\nu_i}.$$

Si $\nu_i = 0$, el estado es absorbente. Una vez que el proceso entra, no sale.

¿Por qué la exponencial?

La exponencial tiene falta de memoria:

$$P(S_i > s + t \mid S_i > s) = P(S_i > t).$$

Conocido el estado actual, no necesitamos guardar cuánto tiempo lleva el sistema en él.

> Si el riesgo cambia con la edad, el estado operativo por sí solo puede ser insuficiente. Debemos incorporar esa información o usar un modelo diferente.

Elegir el siguiente estado

Para $\nu_i > 0$, al salir de i el destino j se elige con probabilidad

$$P(\text{siguiente estado} = j \mid \text{salida de } i) = \frac{q_{ij}}{\nu_i}.$$

Si las tasas de salida son 0.2 y 0.3 por hora:

- la tasa total es $0.5\ \mathrm{h}^{-1}$ y la permanencia media es $2\ \mathrm{h}$.
- las probabilidades de los dos destinos son 0.4 y 0.6.

La tasa total determina **cuándo** se sale. Las razones determinan **hacia dónde**.

Elegir el siguiente estado

Miremos un intervalo muy corto ds mientras el proceso está en i:

- La probabilidad de saltar de i a j es aproximadamente $q_{ij}\,ds$.
- La probabilidad de salir de i hacia cualquier estado es aproximadamente $\nu_i\,ds$.

Si ocurre una salida en ese intervalo, la proporción que va hacia j es

$$\frac{q_{ij}\,ds}{\nu_i\,ds} = \frac{q_{ij}}{\nu_i}.$$

El intervalo ds se cancela. Como las tasas son constantes, esta proporción es la misma cuando ocurra el próximo salto. Por eso da la probabilidad de su destino.

> q_{ij}/ν_i es la probabilidad de que la **próxima transición** desde i vaya a j. No es la probabilidad de encontrar el proceso en j tras un tiempo fijado t.

Próximo salto o estado en un instante

q_{ij}/ν_i da el destino de la próxima transición. Para calcular la probabilidad de estar en j tras un tiempo fijado t, usamos

$$P(t)_{ij} = P(X(t) = j \mid X(0) = i), \qquad P(t) = e^{Qt}.$$

Antes de t pueden ocurrir cero, uno o varios saltos, incluidas salidas y retornos a los estados.

Construcción de la matriz generadora

La matriz generadora Q reúne las tasas instantáneas de cambio y determina cómo evoluciona la distribución de estados en el tiempo. Conservamos la convención de la clase de DTMC:

> **fila = origen, columna = destino.**

Fuera de la diagonal, $q_{ij} \geq 0$. En la diagonal:

$$q_{ii} = -\nu_i = -\sum_{j \neq i} q_{ij}.$$

Cada fila suma cero. La diagonal registra la salida total y no representa una transición del estado hacia sí mismo.

Leer y verificar una fila de Q

En el orden $(0, 1, 2)$, suponga que la primera fila es

$$\begin{bmatrix} -0.5 & 0.2 & 0.3 \end{bmatrix}\ \mathrm{h}^{-1}.$$

Desde 0 se sale hacia 1 a tasa 0.2 y hacia 2 a tasa 0.3. En un intervalo corto h, salir de 0 tiene probabilidad aproximada $(0.2 + 0.3)h$. La diagonal compensa esas salidas para que la fila de probabilidades sume uno: $q_{00} = -(0.2 + 0.3)$.

Al verificar una generadora, revise:

1. tasas no negativas fuera de la diagonal.
2. diagonales no positivas y filas que suman cero.
3. el mismo orden de estados y la misma unidad de tiempo.

Q y la matriz de transición instantánea

Para DTMC, P^n describe la evolución tras n pasos discretos.
Mientras, para CTMC, $P(t)$ describe la **evolución durante un tiempo transcurrido** t, que puede ser cualquier duración real no negativa. t **mide tiempo, no cantidad de saltos**.

Su entrada $P(t)_{ij}$ es la probabilidad de que el proceso, iniciado en i, se encuentre en j después de ese tiempo. La fila indica el estado inicial y la columna el estado observado:

$$P(t)_{ij} = P(X(t) = j \mid X(0) = i).$$

Durante t pueden ocurrir cero, uno o varios cambios de estado. $P(t)$ reúne la probabilidad de todas esas trayectorias que terminan en cada estado.

De las tasas a las probabilidades en h

Para $i \neq j$, la definición de tasa da la probabilidad de saltar de i a j durante un intervalo corto:

$$P(h)_{ij} = q_{ij}h + o(h).$$

La fila de probabilidades debe sumar uno. Entonces, permanecer en i es el complemento de salir hacia los demás estados:

$$P(h)_{ii} = 1 - \sum_{j \neq i} P(h)_{ij} = 1 - \nu_i h + o(h).$$

De las probabilidades a la forma matricial

Las expresiones dentro y fuera de la diagonal se reúnen en una sola regla para las entradas:

$$P(h)_{ij} = \delta_{ij} + hq_{ij} + o(h) \quad \Longrightarrow \quad P(h) = I + hQ + o(h).$$

δ_{ij} vale uno si $i = j$ y cero si $i \neq j$, por eso forma la identidad I. hQ recoge los cambios de primer orden. $o(h)$ representa correcciones despreciables frente a h, como varios saltos en un intervalo corto. Es una aproximación válida para h pequeño, no para intervalos grandes.

Del modelo a la distribución futura

El vector fila $\boldsymbol{p}(t)$ reúne las probabilidades de cada estado en el instante t. Su función es como la de $\boldsymbol{\alpha}$: cada componente indica la probabilidad de estar en un estado.

Recordemos Kolmogorov como un balance: la probabilidad de un estado cambia según el flujo que entra menos el que sale. Para el estado j:

$$\frac{dp_j(t)}{dt} = \sum_{i \neq j} p_i(t) q_{ij} - p_j(t)\nu_j, \qquad \text{equivalentemente} \qquad \boldsymbol{p}'(t) = \boldsymbol{p}(t)Q.$$

Cada producto es un flujo de probabilidad por unidad de tiempo, no una probabilidad: $p_i(t)q_{ij}$ entra a j y $p_j(t)\nu_j$ sale de j.

Más adelante aplicaremos el balance a las reparaciones que entran al estado operativo y las fallas que salen de él.

Ejemplo numérico: cambio inicial de probabilidades

Considere los estados (D, U), con tasa de reparación $\mu = 0.5\ \mathrm{h}^{-1}$ y tasa de falla $\lambda = 0.1\ \mathrm{h}^{-1}$:

$$Q = \begin{bmatrix} -0.5 & 0.5 \\ 0.1 & -0.1 \end{bmatrix}, \qquad \boldsymbol{p}(0) = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Aplicando Kolmogorov:

$$\boldsymbol{p}'(0) = \boldsymbol{p}(0)Q = \begin{bmatrix} 0.1 & -0.1 \end{bmatrix}\ \mathrm{h}^{-1}.$$

Al inicio, la probabilidad de estar caído aumenta a razón de 0.1 por hora y la de estar operativo disminuye a la misma razón. La derivada indica el cambio instantáneo, no las probabilidades en un tiempo futuro.

La misma idea de Chapman y Kolmogorov

La transición durante $t + h$ puede separarse en un primer intervalo de duración t y uno corto de duración h:

$$P(t + h) = P(t)P(h).$$

Cada entrada suma sobre el estado intermedio k: $P(t + h)_{ij} = \sum_k P(t)_{ik} P(h)_{kj}$.

> Esta composición permite combinar la evolución en intervalos cortos para obtenerla en cualquier tiempo.

De $P(h)$ a la ecuación para $P(t)$

Para el intervalo corto usamos $P(h) = I + hQ + o(h)$. El término $o(h)$ se vuelve despreciable frente a h. Por ejemplo, $h^2/h = h \to 0$. Al sustituirlo en la composición:

$$P(t+h) = P(t)(I + hQ + o(h)).$$

Restamos $P(t)$, dividimos por h y hacemos que h tienda a cero:

$$\frac{P(t+h) - P(t)}{h} = P(t)Q + P(t)\frac{o(h)}{h} \longrightarrow P(t)Q.$$

Así obtenemos $P'(t) = P(t)Q$. La condición inicial es $P(0) = I$, porque en tiempo cero el estado no cambia.

Solución: matriz de transición

La solución de $P'(t) = P(t)Q$ con $P(0) = I$ es

$$P(t) = e^{Qt}.$$

Esta solución cumple $\frac{d}{dt}e^{Qt} = e^{Qt}Q$ y $e^{Q\cdot 0} = I$. La exponencial es **matricial**: no se calcula exponenciando cada entrada de Q por separado. Referencia sobre la exponencial matricial (Wikipedia).

Cada entrada $P(t)_{ij}$ da la probabilidad de terminar en j tras tiempo t, partiendo de i.

Aplicar $P(t)$ a la distribución inicial

El vector fila $\boldsymbol{p}(0)$ indica las probabilidades de cada estado al inicio. Para hallar la distribución tras tiempo t, multiplicamos ese vector por la matriz de transición:

$$\boldsymbol{p}(t) = \boldsymbol{p}(0)P(t) = \boldsymbol{p}(0)e^{Qt}.$$

Para cada estado final j, la multiplicación equivale a sumar las contribuciones de todos los estados iniciales i:

$$p_j(t) = \sum_i p_i(0)P(t)_{ij}.$$

Cada producto $p_i(0)P(t)_{ij}$ combina la probabilidad de comenzar en i con la de llegar desde i a j en tiempo t.

Ejemplo: propagar la distribución inicial

Retomemos el sistema reparable en el orden (D, U), con reparación $\mu = 0.5\ \mathrm{h}^{-1}$, falla $\lambda = 0.1\ \mathrm{h}^{-1}$ y partida operativa:

$$Q = \begin{bmatrix} -0.5 & 0.5 \\ 0.1 & -0.1 \end{bmatrix}\ \mathrm{h}^{-1}, \qquad \boldsymbol{p}(0) = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Al cabo de una hora, la matriz de transición es

$$P(1\ \mathrm{h}) = e^{Q(1\ \mathrm{h})} \approx \begin{bmatrix} 0.6240 & 0.3760 \\ 0.0752 & 0.9248 \end{bmatrix}.$$

Ejemplo: propagar la distribución inicial

Entonces,

$$\boldsymbol{p}(1\ \mathrm{h}) = \boldsymbol{p}(0)P(1\ \mathrm{h}) = \begin{bmatrix} 0.0752 & 0.9248 \end{bmatrix}.$$

Como el sistema partió operativo, $\boldsymbol{p}(0)$, las probabilidades de estar caído y operativo son aproximadamente 0.0752 y 0.9248.

- Pendiente inicial: $\boldsymbol{p}'(0) = [0.1, -0.1]\ \mathrm{h}^{-1}$. Si se mantuviera constante, daría $\boldsymbol{p}(1\ \mathrm{h}) \approx [0.1, 0.9]$.
- Resultado con e^{Qt}: $\boldsymbol{p}(1\ \mathrm{h}) = [0.0752, 0.9248]$, incorpora cambios dados por la exponencial.

Servicio reparable: estados y supuestos

Un enlace alterna entre

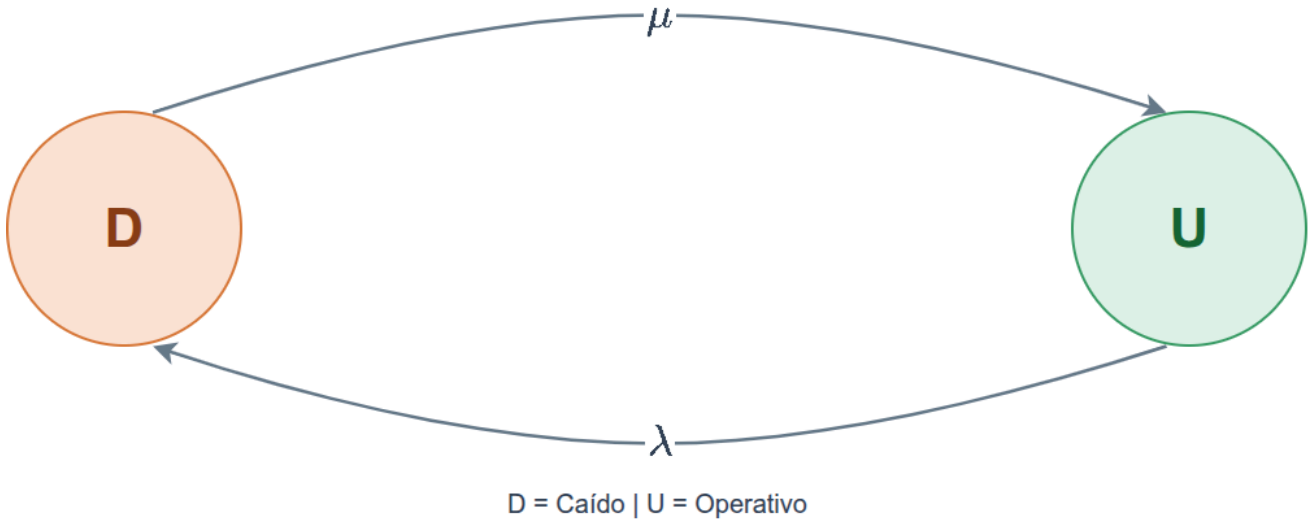
$$D = \text{caído/down}, \qquad U = \text{operativo/up}.$$

Supondremos tiempos exponenciales e independientes:

- tiempo operativo hasta falla, con tasa λ.
- tiempo de restauración, con tasa μ.
- después de restaurarse, el servicio vuelve al mismo estado operativo.

La permanencia en D incluye toda la restauración representada en este modelo, desde la caída hasta el retorno al servicio.

Servicio reparable: diagrama



Las flechas muestran eventos que cambian el estado. La permanencia está descrita por su duración exponencial, no por un bucle con una probabilidad fija.

Servicio reparable: generadora

Con el orden (D, U):

$$Q = \begin{bmatrix} -\mu & \mu \\ \lambda & -\lambda \end{bmatrix}.$$

Las diagonales de Q son negativas de las tasas totales de salida: $\nu_D = \mu$ y $\nu_U = \lambda$.
Como la permanencia en i es exponencial con tasa ν_i, su media es $1/\nu_i$:

$$E[S_D] = \frac{1}{\nu_D} = \frac{1}{\mu}, \qquad E[S_U] = \frac{1}{\nu_U} = \frac{1}{\lambda}.$$

Si parte operativo:

$$\boldsymbol{p}(0) = \begin{bmatrix} 0 & 1 \end{bmatrix}.$$

Ambas filas de Q suman cero y el vector inicial suma uno.

Balance transiente: entradas y salidas

Aplicamos el balance de Kolmogorov al estado operativo U. La probabilidad entra por reparaciones desde D y sale por fallas desde U:

$$\frac{dp_U(t)}{dt} = \underbrace{\mu p_D(t)}_{\text{reparaciones}} - \underbrace{\lambda p_U(t)}_{\text{fallas}}.$$

Como $p_D(t) = 1 - p_U(t)$ y $A(t) = p_U(t)$:

$$A'(t) = \mu - (\lambda + \mu) A(t).$$

La disponibilidad aumenta por reparaciones y disminuye por fallas. Los flujos se ponderan por la probabilidad de estar en el estado de origen.

Disponibilidad de equilibrio

En equilibrio, la disponibilidad deja de cambiar y las reparaciones compensan las fallas:

$$\underbrace{\mu(1 - A_{\text{eq}})}_{\text{flujo de reparación}} = \underbrace{\lambda A_{\text{eq}}}_{\text{flujo de falla}} \quad \Longrightarrow \quad A_{\text{eq}} = \frac{\mu}{\lambda + \mu}.$$

Este es el nivel al que tiende la disponibilidad cuando disminuye la influencia de la condición inicial.

Disponibilidad transiente: resultado

Para $\lambda + \mu > 0$ y cualquier disponibilidad inicial $A(0)$:

$$A(t) = \frac{\mu}{\lambda + \mu} + \left(A(0) - \frac{\mu}{\lambda + \mu} \right) e^{-(\lambda+\mu)t}.$$

El primer término es el equilibrio. El segundo representa el efecto inicial, que decae con el tiempo. Ver la derivación en el anexo.

Disponibilidad y confiabilidad

Si el servicio parte operativo:

$$A(t) = \frac{\mu}{\lambda + \mu} + \frac{\lambda}{\lambda + \mu} e^{-(\lambda+\mu)t}, \qquad R(t) = e^{-\lambda t}.$$

$A(t)$ incluye trayectorias que fallan y se reparan antes de t. $R(t)$ exige no haber fallado durante la misión.

Con $\mu = 0$ y $\lambda > 0$, no hay recuperación y ambas expresiones coinciden. Con reparación, la disponibilidad puede mantenerse alta aunque una misión larga sin fallas sea improbable.

Primera falla y estado al final del intervalo

Partiendo operativo, en el modelo de dos estados:

$$P(\text{primera falla antes de } h) = 1 - e^{-\lambda h}.$$

En cambio, la probabilidad de encontrarlo caído en h es

$$P(X(h) = D \mid X(0) = U) = \frac{\lambda}{\lambda + \mu}\left(1 - e^{-(\lambda+\mu)h}\right).$$

La segunda pregunta permite recuperarse antes de la observación. Ambas probabilidades tienen aproximación λh en intervalos pequeños, pero sus valores exactos son distintos si hay reparación.

¿Qué significa régimen estacionario?

Una distribución estacionaria cumple

$$\boldsymbol{\pi} Q = \mathbf{0}, \qquad \sum_i \pi_i = 1, \qquad \pi_i \geq 0.$$

Si comenzamos con $\boldsymbol{\pi}$, la distribución no cambia con el tiempo.

Para una CTMC **finita e irreducible**, existe una única distribución estacionaria y el transiente converge hacia ella desde cualquier distribución inicial.

En tiempo continuo no necesitamos agregar la condición de aperiodicidad usada en DTMC.

Balance estacionario de dos estados

Con $\lambda, \mu > 0$, ambos estados se comunican. El flujo de fallas compensa el de reparaciones:

$$\pi_U \lambda = \pi_D \mu, \qquad \pi_D + \pi_U = 1.$$

Por tanto,

$$\pi_D = \frac{\lambda}{\lambda + \mu}, \qquad \pi_U = \frac{\mu}{\lambda + \mu}.$$

La disponibilidad estacionaria es $A_\infty = \pi_U$. Coincide con el límite de la solución transiente que acabamos de obtener.

Ejemplo: enlace reparable

Un enlace tiene un tiempo medio operativo de $500\ \mathrm{h}$ y un tiempo medio de restauración de $2\ \mathrm{h}$.

$$\lambda = 0.002\ \mathrm{h}^{-1}, \qquad \mu = 0.5\ \mathrm{h}^{-1}.$$

Entonces,

$$A_\infty = \frac{0.5}{0.502} \approx 0.996016.$$

En régimen estacionario, un año de $8760\ \mathrm{h}$ acumularía en promedio $34.9\ \mathrm{h}$ sin servicio. Es un promedio esperado, no una garantía anual.

Ejemplo: efecto del estado inicial

Con las tasas del enlace anterior y $t = 2\ \mathrm{h}$:

Estado inicial	Disponibilidad aproximada a las dos horas
operativo	0.99748
caído	0.63106

Ambos casos convergen hacia $\mu/(\lambda+\mu) \approx 0.996016$, pero al principio las preguntas son muy distintas.

> Un valor estacionario no describe la recuperación de una caída reciente. Para esa pregunta importa la distribución inicial.

Disponibilidad desde varios estados

Como en DTMC, sea $\mathcal{U}$ el conjunto de estados que cumplen el nivel de servicio:

$$A(t) = \sum_{i \in \mathcal{U}} p_i(t), \qquad A_\infty = \sum_{i \in \mathcal{U}} \pi_i.$$

Un estado degradado puede contar como disponible si satisface el requisito acordado.

La CTMC describe cómo evoluciona el sistema. El criterio de servicio determina qué probabilidades debemos sumar.

Dos componentes: estados y reparación

Ahora analizaremos un sistema reparable con dos componentes idénticos. Definimos $X(t)$ como el número de componentes operativos:

Estado	Condición
0	ambos caídos
1	uno operativo
2	ambos operativos

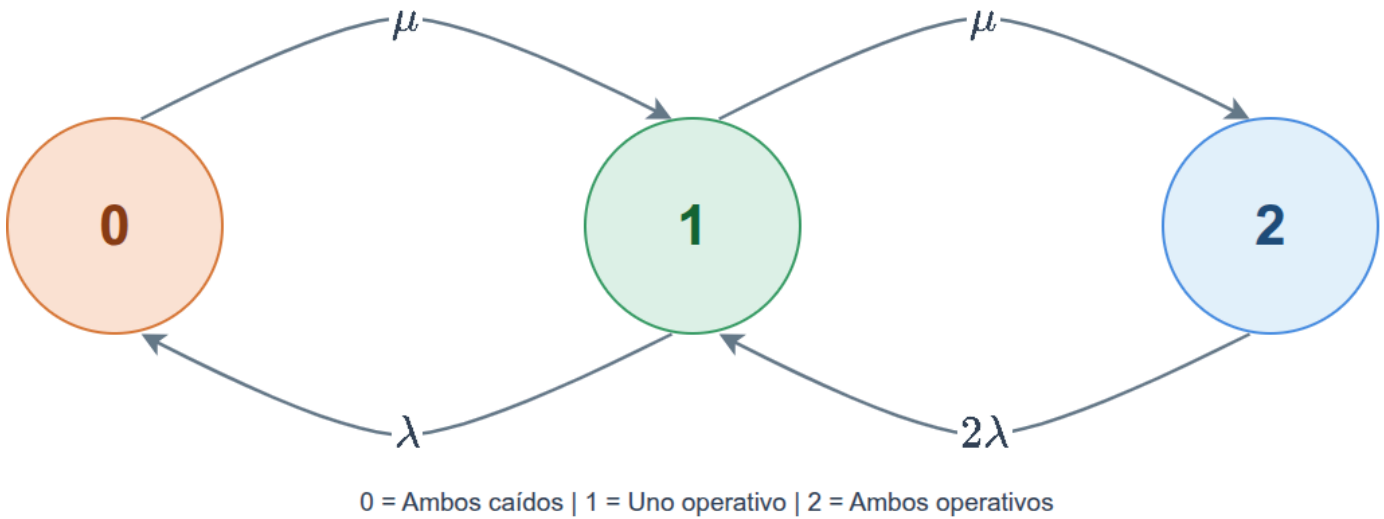
Como la identidad de los componentes no cambia las tasas futuras, basta contar cuántos operan. Cada falla o reparación individual cambia este conteo en una unidad.

Dos componentes: reglas de funcionamiento

- Cada componente operativo falla con tasa $\lambda > 0$.
- Las fallas son independientes y no hay fallas de causa común.
- Un único reparador atiende un componente a la vez con tasa $\mu > 0$ mientras trabaja en él.
- Comienza una reparación tan pronto hay un componente pendiente.
- Un componente operativo puede fallar mientras el otro se repara.

Los tiempos de falla y reparación activa son exponenciales. No incluimos otras esperas en esta versión del modelo.

Dos componentes: diagrama de tasas



Desde 2 puede fallar cualquiera de los dos componentes. Por eso la tasa total hacia 1 es 2λ.

Desde 0 hay dos componentes pendientes, pero solo un reparador. La tasa hacia 1 sigue siendo μ.

Dos componentes: generadora

En el orden $(0, 1, 2)$:

$$Q = \begin{bmatrix} -\mu & \mu & 0 \\ \lambda & -(\lambda + \mu) & \mu \\ 0 & 2\lambda & -2\lambda \end{bmatrix}.$$

En el estado 1 compiten falla y reparación, con permanencia media $1/(\lambda + \mu)$.

Los ceros indican que no hay un evento individual que cambie directamente desde 0 a 2 o desde 2 a 0.

Dos componentes: obtener el estacionario

Entre estados vecinos:

$$\pi_0\mu = \pi_1\lambda, \qquad \pi_1\mu = \pi_2(2\lambda).$$

Defina $x = \mu/\lambda$. Entonces

$$\pi_1 = x\pi_0, \qquad \pi_2 = \frac{x^2}{2}\pi_0.$$

Al normalizar:

$$\pi_0 = \frac{1}{1 + x + x^2/2}.$$

Estas ecuaciones de balance local son válidas para esta estructura lineal. Una CTMC general se resuelve con el balance global $\boldsymbol{\pi}Q = 0$.

Dos componentes: ejemplo numérico

Use $\lambda = 0.1\ \mathrm{h}^{-1}$ y $\mu = 1\ \mathrm{h}^{-1}$. Así, $x = 10$:

$$\boldsymbol{\pi} = \frac{1}{61}\begin{bmatrix} 1 & 10 & 50 \end{bmatrix}.$$

Si basta un componente operativo:

$$A_\infty = \pi_1 + \pi_2 = \frac{60}{61} \approx 0.983607.$$

Si se exige capacidad completa, $A_\infty = \pi_2 = 50/61 \approx 0.819672$. El modelo es el mismo y cambia el conjunto $\mathcal{U}$.

¿Qué ocurre con reparadores independientes?

Si cada componente puede repararse simultáneamente y de forma independiente, desde 0 la tasa de primera recuperación es 2μ.

Las demás tasas no cambian. El estacionario pasa a ser

$$\boldsymbol{\pi} = \frac{1}{(1+x)^2}\begin{bmatrix} 1 & 2x & x^2 \end{bmatrix}.$$

Con $x = 10$, la disponibilidad con al menos uno operativo es $120/121 \approx 0.991736$.

La reparación compartida introduce dependencia aunque las fallas sean independientes. La política de soporte forma parte del modelo.

Prioridad de reparación: elegir el estado

Consideremos un sistema de acceso a archivos con un servidor y dos estaciones de trabajo. Un reparador prioriza el servidor y suspende la reparación de las estaciones mientras este está caído.

Definimos el estado (w, f):

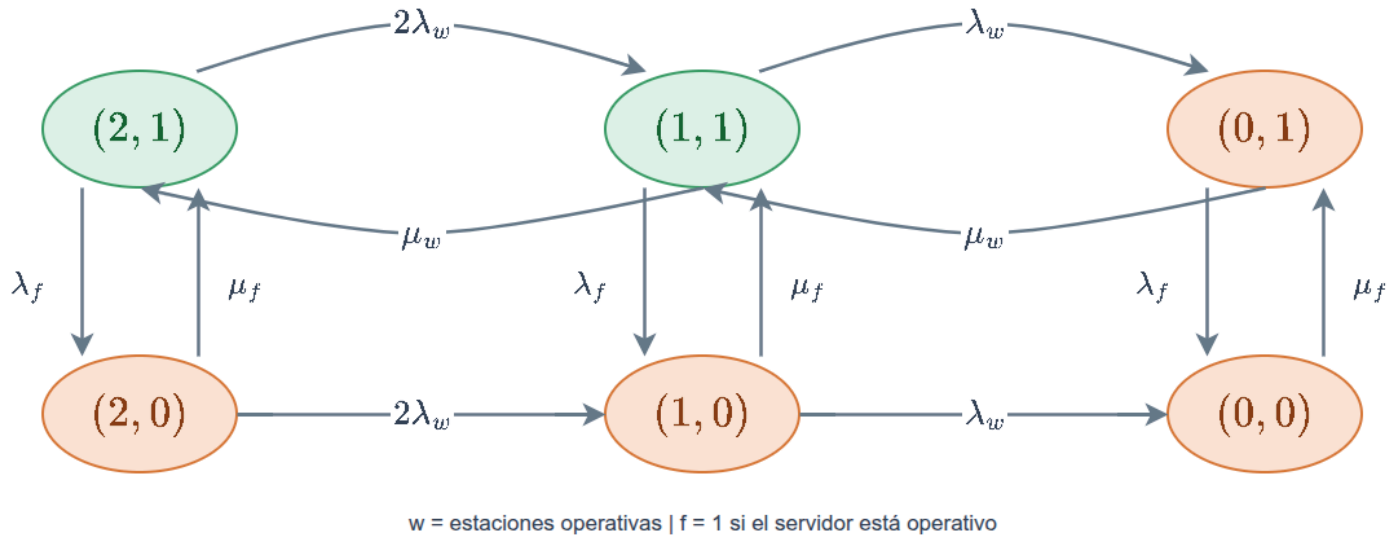
- $w \in \{0, 1, 2\}$ es el número de estaciones operativas.
- $f \in \{0, 1\}$ indica si el servidor está operativo.
- el servicio requiere $f = 1$ y al menos una estación operativa.

Prioridad de reparación: parámetros

Parámetro	Evento que describe
λ_w	falla de cada estación operativa
μ_w	reparación activa de una estación
λ_f	falla del servidor operativo
μ_f	reparación activa del servidor

Supondremos tiempos exponenciales independientes, tasas constantes y un único reparador. El servidor tiene prioridad con interrupción sobre las estaciones. La red de comunicación se considera disponible.

Prioridad de reparación: transiciones



w = estaciones operativas | f = 1 si el servidor está operativo

Las fallas de las estaciones continúan aunque el servidor esté caído. En la fila inferior no hay reparación de estaciones, porque el reparador atiende al servidor.

Supondremos tiempos exponenciales y prioridad con interrupción. Bajo estos supuestos no hace falta guardar el tiempo de reparación ya transcurrido.

Prioridad de reparación: leer una fila

Desde $(1, 1)$ pueden ocurrir tres eventos:

Evento	Destino	Tasa
falla la estación operativa	$(0, 1)$	λ_w
se repara la otra estación	$(2, 1)$	μ_w
falla el servidor	$(1, 0)$	λ_f

La diagonal de esa fila es $-(\lambda_w + \mu_w + \lambda_f)$.

Cuando el servidor está caído, el estado $(1, 0)$ tiene una tasa total de salida distinta: $\lambda_w + \mu_f$.

Prioridad de reparación: disponibilidad

El objetivo aquí es construir la CTMC, definir sus transiciones y fijar qué estados prestan servicio. Para obtener una disponibilidad numérica, se asignan valores a las tasas y se resuelve $\boldsymbol{\pi} Q = \mathbf{0}$, junto con $\sum_i \pi_i = 1$. Los estados que cuentan como servicio son

$$\mathcal{U} = \{(1,1), (2,1)\}.$$

La disponibilidad de largo plazo se obtiene sumando las probabilidades estacionarias de esos estados:

$$A_\infty = \pi_{(1,1)} + \pi_{(2,1)}.$$

Con dos estaciones operativas y el servidor caído, el estado $(2,0)$ no presta el servicio requerido. Por eso no basta con contar estaciones sin guardar la condición del servidor.

Nacimiento y muerte

Una CTMC tiene estructura de nacimiento y muerte cuando solo cambia entre estados vecinos:

$$0 \rightleftarrows 1 \rightleftarrows 2 \rightleftarrows \cdots$$

Si λ_i es la tasa desde i a $i+1$ y μ_i la tasa desde i a $i-1$, con tasas positivas entre vecinos, el estacionario satisface:

$$\pi_i \lambda_i = \pi_{i+1} \mu_{i+1}.$$

Los nombres nacimiento y muerte indican aumento y disminución del estado. Según cómo lo definamos, una reparación puede ser un nacimiento.

Nacimiento y muerte: normalización

Al aplicar el balance entre vecinos:

$$\pi_n = \pi_0 \prod_{i=0}^{n-1} \frac{\lambda_i}{\mu_{i+1}}.$$

Después se impone $\sum_n \pi_n = 1$ para obtener π_0.

En una cadena finita, la suma tiene un número finito de términos. Si hay infinitos estados, también debemos verificar que la suma converja.

Esta condición será la base de la estabilidad de las filas.

Modelo de máquinas con un reparador

Considere M máquinas y defina n como el número **fallado**.

$$n \to n+1: \ (M-n)\lambda, \qquad n \to n-1: \ \mu \quad (n>0).$$

Solo las máquinas operativas pueden fallar. Un reparador atiende una máquina a la vez.

$$\pi_n = \pi_0 \left(\frac{\lambda}{\mu}\right)^n \frac{M!}{(M-n)!}, \qquad 0 \le n \le M.$$

Normalizamos sumando estos $M+1$ términos. Aquí los estados cuentan fallas, no componentes operativos como en el ejemplo anterior.

Una cadena, varias métricas

Asigne un valor r_i a cada estado. El promedio instantáneo y el estacionario son

$$E[r(X(t))] = \sum_i p_i(t) r_i, \qquad \overline{r} = \sum_i \pi_i r_i.$$

Valor asociado al estado	Métrica
1 si presta servicio y 0 si no	disponibilidad
capacidad disponible	capacidad media
costo por hora	costo medio por hora

La unidad del resultado es la unidad del valor que asignamos al estado.

Ejemplo: capacidad y disponibilidad

En el ejemplo de dos componentes y un reparador:

$$\boldsymbol{\pi} = \frac{1}{61}\begin{bmatrix} 1 & 10 & 50 \end{bmatrix}.$$

Si cada componente ofrece 10 Mbps, las capacidades por estado son $r = (0, 10, 20)$ Mbps:

$$\overline{r} = \frac{1(0) + 10(10) + 50(20)}{61} \approx 18.033 \text{ Mbps}.$$

La disponibilidad $60/61$ cuenta estados aceptables. La capacidad media pondera cuánto puede entregar cada uno. No son la misma métrica.

Del valor instantáneo a una cantidad acumulada

Si r_i es una tasa de recompensa, la cantidad esperada durante $[0, T]$ es

$$E[Y(T)] = \int_0^T \sum_i p_i(t) r_i \, dt.$$

Con $r_i = 1$ en estados sin servicio y 0 en los demás, obtenemos las horas esperadas de inactividad.

Si el intervalo comienza en régimen estacionario, $E[Y(T)] = T \sum_i \pi_i r_i$. Si importa el arranque, debemos integrar las probabilidades transientes. La unidad temporal de r_i debe ser compatible con la de T.

Ejercicio: servidor reparable

Un servidor tiene tiempos exponenciales de operación y restauración. El tiempo medio operativo es $1000\ \mathrm{h}$ y el de restauración es $4\ \mathrm{h}$. Parte operativo.

1. Construya Q en el orden (D, U).
2. Determine la distribución estacionaria y A_∞.
3. Calcule $A(10)$ y $R(10)$.
4. Estime las horas anuales de inactividad en régimen estacionario.
5. Explique qué cambia si el servidor parte caído.

Solución: tasas y generadora

Como los tiempos de operación y restauración son exponenciales, sus tasas son los inversos de sus medias:

$$\lambda = \frac{1}{1000} = 0.001\ \mathrm{h}^{-1}, \qquad \mu = \frac{1}{4} = 0.25\ \mathrm{h}^{-1}.$$

En el orden (D, U), desde D se restaura a tasa μ y desde U se falla a tasa λ. Las diagonales son negativas de las tasas de salida:

$$Q = \begin{bmatrix} -0.25 & 0.25 \\ 0.001 & -0.001 \end{bmatrix}\ \mathrm{h}^{-1}.$$

Solución: distribución estacionaria

En equilibrio, el flujo de fallas iguala al de reparaciones, y las probabilidades suman uno:

$$\pi_D \mu = \pi_U \lambda, \qquad \pi_D + \pi_U = 1.$$

La primera ecuación da $\pi_U / \pi_D = \mu / \lambda = 250$. Al normalizar, $\pi_D = 1/251$ y $\pi_U = 250/251$:

$$\boldsymbol{\pi} = \frac{1}{251} \begin{bmatrix} 1 & 250 \end{bmatrix}.$$

El servicio está disponible solo en U, por lo que $A_\infty = \pi_U = 250/251 \approx 0.996016$.

Solución: inactividad anual esperada

En un año de 8760 horas iniciado en régimen estacionario, la fracción de tiempo caído es $\pi_D = 1 - A_\infty$:

$$E[T_D] = (1 - A_\infty)(8760\ \mathrm{h}) = \frac{8760}{251}\ \mathrm{h} \approx 34.9\ \mathrm{h}.$$

Es una esperanza basada en el régimen estacionario, no una duración garantizada para cada año.

Solución: inicio operativo

En la solución transiente, $A_\infty = 250/251$, $A(0) = 1$ y $\lambda + \mu = 0.251\ \mathrm{h}^{-1}$:

$$A(10) = \frac{250}{251} + \frac{1}{251} e^{-0.251(10)} \approx 0.996340.$$

La confiabilidad exige no fallar durante las diez horas. Como el tiempo hasta la primera falla es exponencial:

$$R(10) = e^{-\lambda(10)} = e^{-0.001(10)} \approx 0.990050.$$

$A(10)$ permite fallas seguidas de reparación, mientras que $R(10)$ no.

Solución: inicio caído

Si parte caído, $A(0) = 0$. Sustituyendo en la misma solución transiente:

$$A(10) = \frac{250}{251}\left(1 - e^{-(0.001+0.25)(10)}\right) \approx 0.915071.$$

La probabilidad es menor que al partir operativo, porque el sistema debe recuperarse antes de estar disponible.

Cierre

Construimos una CTMC siguiendo la secuencia

$$\text{estados} \to \text{eventos y tasas} \to Q \to \text{probabilidades} \to \text{métricas}.$$

La reparación compartida y las prioridades modifican las transiciones. Los valores por estado permiten medir disponibilidad, capacidad y costos.

Los próximos contenidos relacionan estos resultados con tiempos medios, registros de fallas y acuerdos de nivel de servicio, y aplican modelos de nacimiento y muerte al estudio de solicitudes en espera.

Anexo: derivación de la solución transiente

Partimos del balance $A'(t) = \mu - (\lambda + \mu)A(t)$. En equilibrio $A' = 0$, por lo que

$$A_{\text{eq}} = \frac{\mu}{\lambda + \mu}.$$

Defina la diferencia respecto del equilibrio como $\Delta(t) = A(t) - A_{\text{eq}}$. Al sustituir en el balance:

$$\Delta'(t) = -(\lambda + \mu)\Delta(t).$$

Por tanto, la diferencia decae exponencialmente:

$$\frac{d}{dt}\left(e^{(\lambda+\mu)t}\Delta(t)\right) = 0 \quad \Longrightarrow \quad \Delta(t) = \Delta(0)e^{-(\lambda+\mu)t}.$$

Anexo: incorporar la condición inicial

Como $A(t) = A_{\text{eq}} + \Delta(t)$ y $\Delta(0) = A(0) - A_{\text{eq}}$, resulta

$$A(t) = \frac{\mu}{\lambda + \mu} + \left(A(0) - \frac{\mu}{\lambda + \mu} \right) e^{-(\lambda+\mu)t}.$$

Si el servicio parte operativo, $A(0) = 1$. Si parte caído, $A(0) = 0$. La escala temporal de decaimiento del efecto inicial es $1/(\lambda + \mu)$.

Referencias

- J. M. Martínez, *Continuous Time Markov Chains*, material histórico TEL211, USM. Definiciones y balance, páginas 6 a 20. Reparación y recompensas, páginas 21 a 40.
- K. S. Trivedi y A. Bobbio, *Reliability and Availability Engineering: Modeling, Analysis, and Applications*, Cambridge University Press, 2017, capítulos 7 y 8.
- W. J. Stewart, *Probability, Markov Chains, Queues, and Simulation*, Princeton University Press, 2009, capítulos 6 a 8.