TEL211

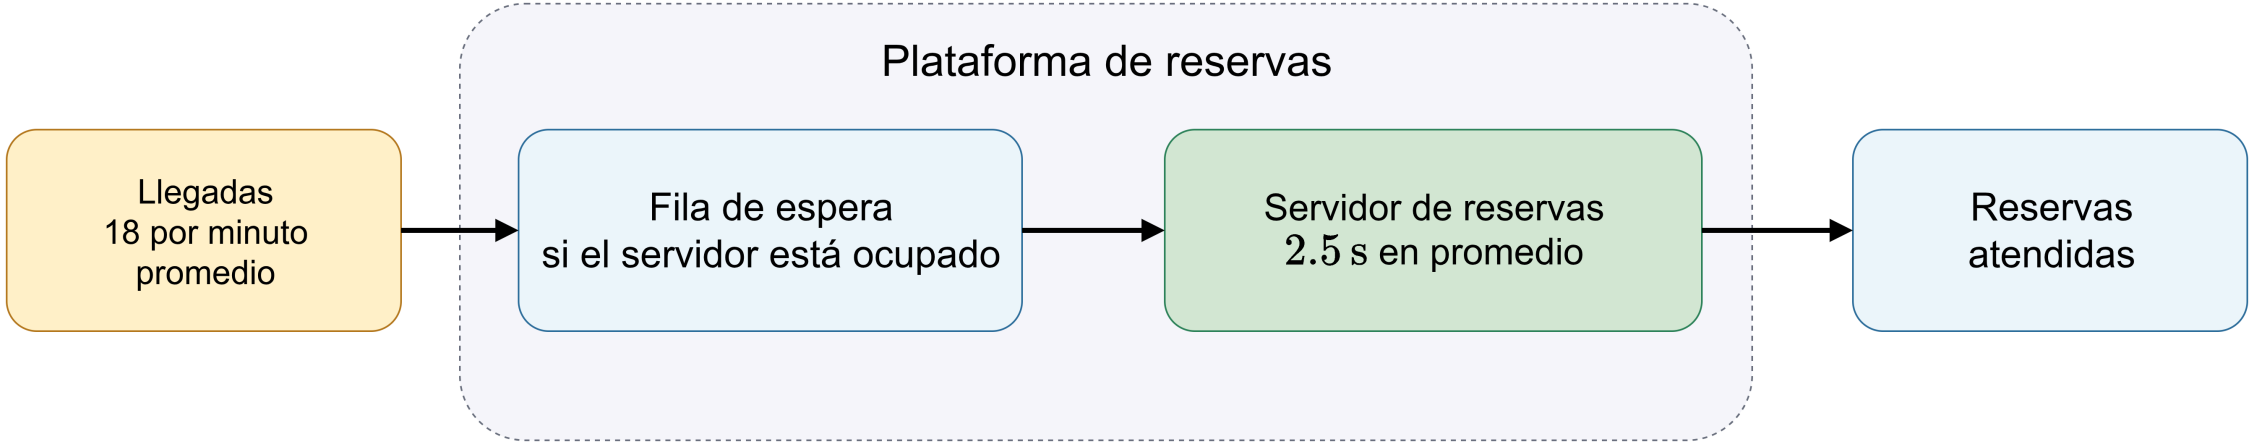
Disponibilidad y Rendimiento de Sistemas de Tecnologías de Información y Comunicaciones (TIC)

Teoría de filas: de la carga al tiempo de respuesta

Patricio Olivares R.
Universidad Técnica Federico Santa María

Un servicio puede estar disponible y responder tarde

En hora punta llegan $18\ \text{solicitudes}\,\text{min}^{-1}$ a una plataforma de reservas. Un servidor tarda, en promedio, $2.5\ \text{s}$ en atender cada solicitud.



Si el servidor está ocupado, la nueva solicitud espera. El servicio sigue disponible, pero la disponibilidad no indica cuánto demora cada respuesta.

¿Qué estudia la teoría de filas?

La teoría de filas estudia sistemas donde solicitudes llegan, esperan si los servidores están ocupados, reciben servicio y salen. Si no queda espacio, se rechazan.

Un modelo describe las llegadas, el espacio de espera, la capacidad de servicio y el orden de atención. Así permite estimar tiempos de respuesta, solicitudes acumuladas, utilización y bloqueo.

Qué observaremos bajo carga

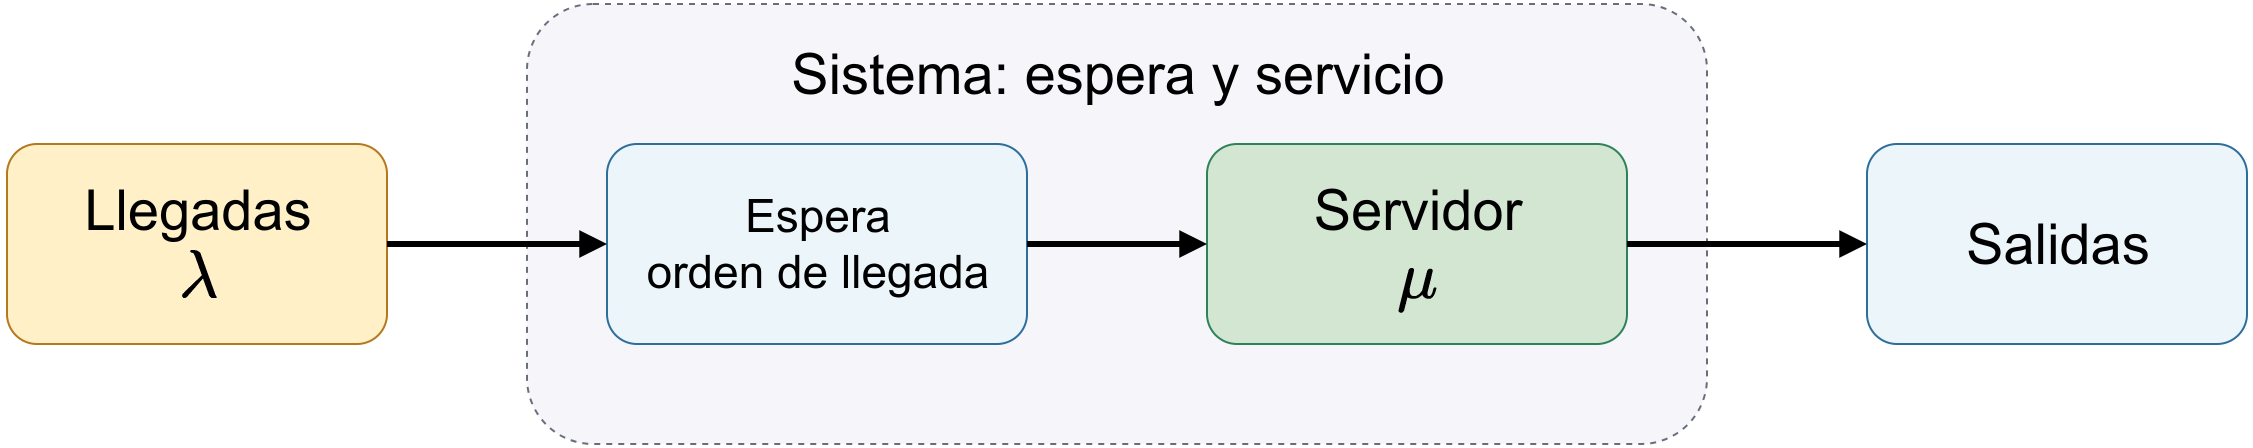
Pregunta	Medida
¿Cuánto tarda una solicitud, en promedio?	W (*waiting*): desde la admisión hasta la salida. W_q: solo la espera.
¿Cuántas solicitudes hay, en promedio?	L (*line*): en todo el sistema. L_q: solo en espera.
¿Qué fracción del tiempo está ocupado el servidor?	Utilización ρ
¿Qué probabilidad hay de rechazar una llegada?	Bloqueo P_{B} y tasa efectiva λ_{e}
¿Cuántos servidores satisfacen el objetivo?	Capacidad y latencia para un SLA

Magnitudes y frontera

Magnitud	Significado	Unidad típica
λ	tasa de llegada ofrecida	$\text{solicitudes}\,\text{s}^{-1}$
λ_{e}	tasa efectiva admitida	$\text{solicitudes}\,\text{s}^{-1}$
μ	tasa de servicio por servidor	$\text{solicitudes}\,\text{s}^{-1}$
L, L_q	número medio en sistema y en espera	solicitudes
W, W_q	tiempo medio en sistema y en espera	s
ρ	utilización: fracción de capacidad ocupada	adimensional
P_{B}	probabilidad de bloqueo	adimensional

Un acuerdo de nivel de servicio (SLA) fija el objetivo de latencia, bloqueo u otra métrica que se debe satisfacer.

Anatomía de una fila



La frontera del sistema incluye a quienes esperan y a quienes están en servicio. Una llegada puede entrar o ser rechazada si no queda espacio.

El tiempo de respuesta va desde la admisión hasta la salida. El tiempo de espera termina cuando comienza el servicio.

Llegadas y servicio en Kendall

A viene de *Arrival* y describe los tiempos entre llegadas. S viene de *Service* y describe los tiempos de servicio. Cada campo puede tomar uno de estos valores:

Valor	Significado
M	*Markovian*. La exponencial no tiene memoria. En A corresponde a llegadas Poisson y en S a servicio exponencial.
D	*Deterministic*. El tiempo entre llegadas o el tiempo de servicio es fijo.
G	*General*. Se permite otra distribución de probabilidad.

Servidores, capacidad, población y disciplina

Los campos restantes describen los recursos y las reglas del sistema:

Campo	Significado
c	Número de servidores en paralelo.
K	Capacidad máxima dentro del sistema, incluido quien recibe servicio.
N	*Number* de fuentes posibles de solicitudes.
D	*Discipline*, regla que decide quién sigue. FCFS (*First Come, First Served*) atiende en orden de llegada.

En los campos A o S, D significa *Deterministic*. Como último campo, D significa *Discipline*.

Notación

Los seis campos aparecen en este orden: $A/S/c/K/N/D$. El símbolo ∞ indica que la capacidad o la población no tienen límite.

Por ejemplo, $M/M/2/10/\infty/\mathrm{FCFS}$ describe llegadas Poisson, servicio exponencial, dos servidores, capacidad total de diez, población ilimitada y atención en orden de llegada.

Aquí $N(t)$ representa el número de solicitudes dentro del sistema en el instante t. En Kendall, N representa la población fuente.

Ejemplos de modelos de Kendall

$M/M/1$ representa llegadas Poisson, servicios exponenciales y un servidor. Si no se especifica, se suponen capacidad y población infinitas.

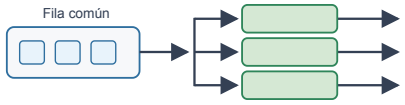
$M/M/1/K$ limita el número total de solicitudes. Con $K = 4$, una recibe servicio y hasta tres esperan.

$M/M/c$ tiene c servidores en paralelo y una fila común. La tasa μ corresponde a cada servidor.

La abreviatura resume supuestos que deben coincidir con el proceso real.

Modelos de sistemas de atención

Los modelos cambian en número de servidores y límite de solicitudes admitidas.

Modelo	Esquema	Qué permite estudiar
$M/M/1$		Un servidor y espera ilimitada. Permite estudiar utilización, número medio y tiempo de respuesta.
$M/M/1/K$		K limita el total, incluida la solicitud atendida. Si se llena, rechaza llegadas. Permite estudiar bloqueo y pérdidas.
$M/M/c$		Una fila común alimenta c servidores. Si todos están ocupados, hay espera. Permite estudiar el efecto de agregar servidores.

Proceso Poisson en sistemas de atención

Las solicitudes llegan de forma independiente y a una tasa media constante λ. Sea $N_A(t)$ el número de llegadas durante un intervalo de duración t. Para $k = 0, 1, 2, \ldots$, $k!$ indica el factorial de k:

$$P(N_A(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \qquad k = 0, 1, 2, \ldots$$

Con $\lambda = 6\ \text{solicitudes}\,\text{min}^{-1}$, la probabilidad de recibir exactamente dos solicitudes en un minuto es:

$$P(N_A(1\ \text{min}) = 2) = \frac{6^2 e^{-6}}{2!} \approx 0.0446.$$

Tiempos entre llegadas en sistemas de atención

Si las llegadas siguen un proceso de Poisson, los tiempos T entre llegadas consecutivas son independientes y exponenciales. Para un umbral temporal t, la cola de T y su media $E[T]$ son:

$$P(T > t) = e^{-\lambda t}, \qquad E[T] = \frac{1}{\lambda}.$$

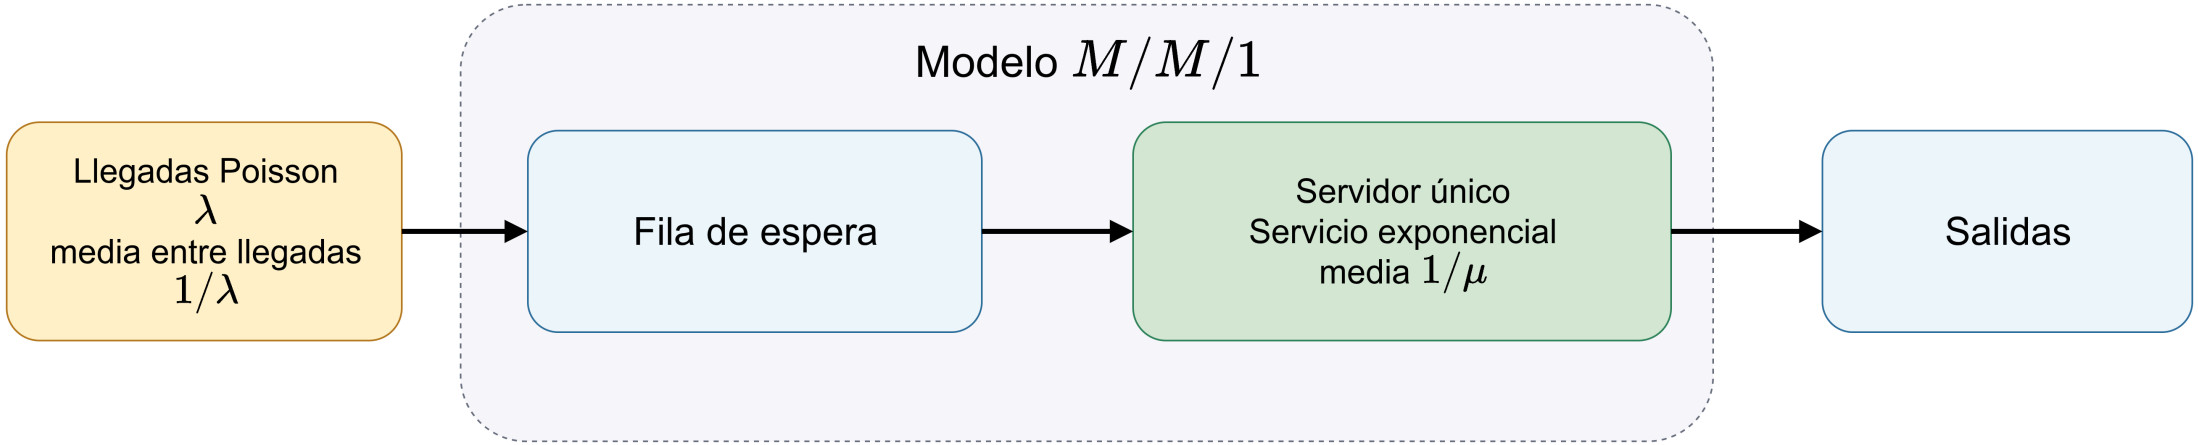
Con $\lambda = 6\ \mathrm{min}^{-1}$, el tiempo medio es $1/6\ \mathrm{min} = 10\ \mathrm{s}$.

La distribución exponencial no tiene memoria. Para una espera previa s y un periodo adicional t:

$$P(T > s + t \mid T > s) = P(T > t).$$

Haber esperado s sin una llegada no cambia la distribución del tiempo restante.

Poisson y servicio en $M/M/1$



La primera M indica llegadas Poisson, con tiempos entre llegadas exponenciales de media $1/\lambda$. La segunda M indica tiempos de servicio exponenciales de media $1/\mu$. El 1 representa un servidor. Las llegadas y los tiempos de servicio se suponen independientes.

Ley de Little

Conocemos el número medio de solicitudes presentes y cuántas se completan por segundo. ¿Cuánto permanece cada solicitud?

En régimen estable, la Ley de Little relaciona estas medidas:

$$L = \lambda_{\mathrm{e}} W$$

L cuenta las solicitudes en el sistema. W es su tiempo medio desde la admisión hasta la salida y λ_{e} la tasa efectiva admitida.

Para esas mismas solicitudes mientras esperan:

$$L_q = \lambda_{\mathrm{e}} W_q$$

L_q cuenta las solicitudes en espera y W_q es su tiempo medio de espera.

> No requiere distribuciones exponenciales. Use la misma población y frontera.

¿De dónde sale la Ley de Little?

Más solicitudes completadas por segundo o más tiempo de permanencia implican más solicitudes presentes. Si se completan $10\ \text{solicitudes}\,\text{s}^{-1}$ y cada una permanece $2\ \text{s}$, hay 20 solicitudes en promedio:

$$(10\ \text{solicitudes}\,\text{s}^{-1})(2\ \text{s}) = 20\ \text{solicitudes}.$$

El producto de la tasa por el tiempo de permanencia da el número medio de solicitudes presentes.

El área bajo $N(t)$

En cada instante t, $N(t)$ cuenta las solicitudes en el sistema. El área $\int_0^T N(t)\,\mathrm{d}t$ suma su tiempo total de permanencia durante una observación de duración T.

En una observación larga, el efecto de sus extremos es pequeño. El tiempo acumulado se aproxima a $C(T)W$, donde $C(T)$ es el número de solicitudes completadas. Como $C(T)/T$ se aproxima a λ_e:

$$L = \lim_{T\to\infty} \frac{1}{T}\int_0^T N(t)\,\mathrm{d}t = \lim_{T\to\infty} \frac{C(T)}{T} W = \lambda_\mathrm{e} W.$$

Ejemplo Ley de Little

Una interfaz de programación de aplicaciones (API) completa 120 solicitudes por segundo y se observan, en promedio, 18 solicitudes dentro del sistema.

$$W = \frac{L}{\lambda_{\mathrm{e}}} = \frac{18}{120\ \mathrm{s}^{-1}} = 0.15\ \mathrm{s}$$

Si $L_q = 12$:

$$W_q = \frac{12}{120\ \mathrm{s}^{-1}} = 0.10\ \mathrm{s}$$

Por diferencia, el tiempo medio en servicio es $0.05\ \mathrm{s}$.

Espera y servicio

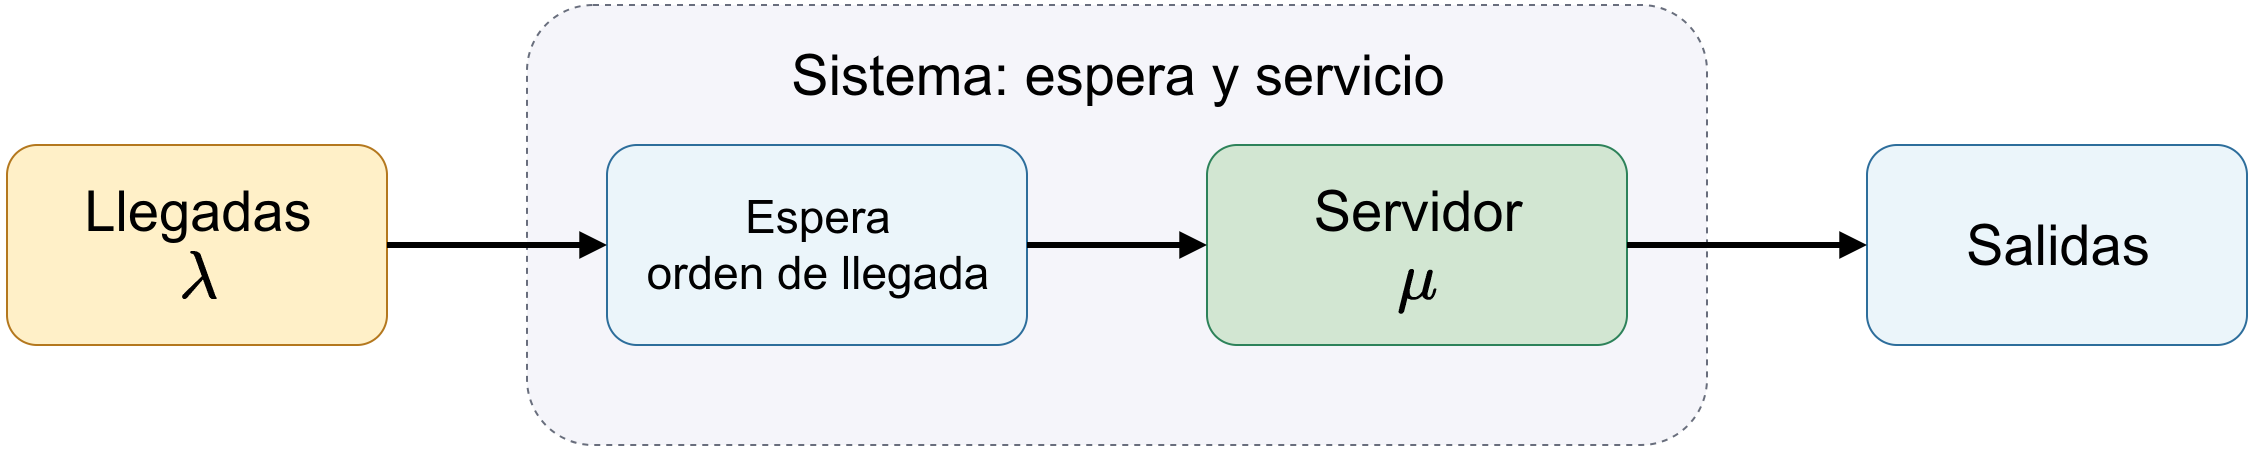
El tiempo medio de respuesta se descompone en el tiempo medio de espera y el tiempo medio de servicio. Si cada solicitud admitida recibe un servicio que dura, en promedio, $1/\mu$:

$$W = W_q + \frac{1}{\mu}.$$

En el ejemplo, $0.15\ \mathrm{s} = 0.10\ \mathrm{s} + 0.05\ \mathrm{s}$. Esta igualdad descompone el tiempo de respuesta. No es la Ley de Little.

Modelo $M/M/1$

En $M/M/1$, las solicitudes llegan al azar, pueden esperar si el servidor está ocupado y son atendidas por un único servidor.



Las llegadas siguen un proceso de Poisson con tasa λ. Los tiempos de servicio son exponenciales con tasa μ. El servidor atiende en orden de llegada.

Se suponen capacidad de espera y población fuente ilimitadas. El proceso de llegadas y los tiempos de servicio son independientes.

Utilización y estabilidad

λ es el número medio de solicitudes que llegan por unidad de tiempo. μ es el número que un servidor ocupado puede atender por unidad de tiempo.

La utilización es:

$$\rho = \frac{\lambda}{\mu}.$$

En régimen estacionario, ρ es la fracción del tiempo que el servidor está ocupado. Los tres casos son:

Condición	Comportamiento
$\lambda < \mu$	Estable. Existe régimen estacionario con un número medio finito de solicitudes.
$\lambda = \mu$	Límite de estabilidad. No hay distribución estacionaria.
$\lambda > \mu$	Sobrecarga. La fila crece sin límite a largo plazo.

Cuando la llegada supera el servicio

Si llegan $12\ \text{solicitudes}\,\text{min}^{-1}$ y el servidor puede atender $10\ \text{solicitudes}\,\text{min}^{-1}$:

$$\lambda = 12, \qquad \mu = 10, \qquad \rho = \frac{12}{10} = 1.2.$$

El valor $\rho = 1.2$ no significa que el servidor esté ocupado el 120% del tiempo. Fuera del régimen estable, ρ compara la carga ofrecida con la capacidad.

La tasa de llegada supera la capacidad en dos solicitudes por minuto. A largo plazo, la acumulación crece aproximadamente a ese ritmo.

Las fórmulas estacionarias de $M/M/1$ solo se aplican bajo esta condición:

$$\boxed{\lambda < \mu \quad \Longleftrightarrow \quad \rho < 1}.$$

Incluso en este régimen, la variabilidad puede formar filas.

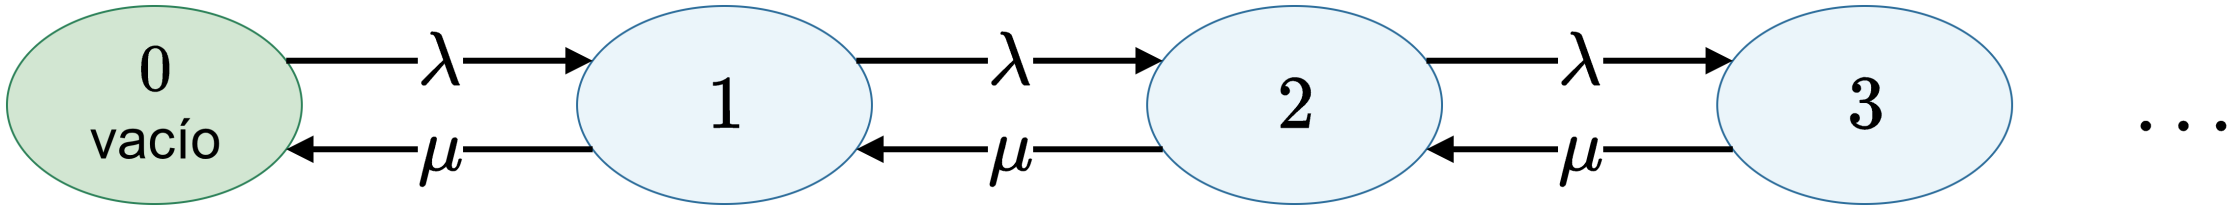
¿Por qué se forma una fila si $\lambda < \mu$?

Aunque la llegada media sea menor que la capacidad, algunas solicitudes pueden coincidir mientras el servidor está ocupado. Para seguir la acumulación usamos el estado

$$N(t) = \text{número de solicitudes dentro del sistema.}$$

Con servicio exponencial, basta conocer cuántas solicitudes hay. Otras distribuciones pueden exigir más información sobre el servicio en curso.

$M/M/1$ como proceso de nacimiento y muerte



El estado n cuenta las solicitudes en el sistema. El proceso cambia el estado de uno en uno. Cada llegada es un nacimiento y cada servicio completado es una muerte.

$$n \to n+1 \text{ a tasa } \lambda$$

$$n \to n-1 \text{ a tasa } \mu, \qquad n \geq 1$$

Distribución estacionaria de $M/M/1$

Sea π_n la probabilidad estacionaria de tener n solicitudes. π_0 corresponde al sistema vacío.

En equilibrio se igualan los flujos vecinos. Cada flujo es la probabilidad del estado de origen por su tasa de transición:

$$\pi_n \lambda = \pi_{n+1} \mu \quad \Longrightarrow \quad \pi_n = \rho^n \pi_0.$$

Al normalizar, la serie geométrica converge si $\rho < 1$:

$$1 = \sum_{n=0}^{\infty} \pi_n = \pi_0 \sum_{n=0}^{\infty} \rho^n = \frac{\pi_0}{1-\rho} \quad \Longrightarrow \quad \pi_0 = 1-\rho, \qquad \pi_n = (1-\rho)\rho^n.$$

La suma es una serie geométrica infinita: $\sum_{n=0}^{\infty} \rho^n = \frac{1}{1-\rho}$, válida para $0 \leq \rho < 1$. Ver serie geométrica.

Interpretar la estabilidad

La serie geométrica converge solo si $\rho < 1$. En $M/M/1$, esta condición permite normalizar la distribución estacionaria.

Si $\lambda = \mu$, no hay régimen estacionario con promedios finitos. Si $\lambda > \mu$, la carga supera la capacidad.

En ambos casos fallan las fórmulas estacionarias de $M/M/1$. Se puede reducir llegadas, aumentar el servicio o agregar servidores. Limitar la capacidad evita una fila infinita, pero causa pérdidas.

Obtener el número medio en el sistema

Con $\pi_n = (1-\rho)\rho^n$:

$$L = \sum_{n=0}^{\infty} n\pi_n = (1-\rho)\sum_{n=0}^{\infty} n\rho^n.$$

Esta suma es un caso de una serie aritmético-geométrica:

$$\sum_{n=0}^{\infty} n\rho^n = \frac{\rho}{(1-\rho)^2}.$$

Por tanto:

$$L = \frac{\rho}{1-\rho}.$$

Número medio en espera

Sea N el número de solicitudes en el sistema y Q el número esperando. Como hay un solo servidor:

$$Q = N - \mathbf{1}_{\{N \geq 1\}},$$

con el indicador igual a uno si el servidor está ocupado y cero si está libre. En régimen estacionario:

$$L_q = \mathbb{E}[Q] = \mathbb{E}[N] - \mathbb{P}(N \geq 1) = L - \mathbb{P}(\text{servidor ocupado}).$$

En $M/M/1$, $\pi_0 = 1 - \rho$, por lo que:

$$\mathbb{P}(N \geq 1) = 1 - \pi_0 = \rho,$$

Por tanto, el número medio total se descompone en solicitudes en espera y en servicio. Como hay un solo servidor, el número medio en servicio es ρ:

$$L = L_q + \rho \quad \Longrightarrow \quad L_q = L - \rho.$$

Métricas de $M/M/1$

> Estas fórmulas describen promedios estacionarios y se aplican cuando $\rho < 1$.

Número medio de solicitudes

L cuenta las solicitudes en espera y en servicio. L_q cuenta solo las que esperan. Como se explicó antes, $L_q = L - \rho$.

$$L = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda},$$

$$L_q = \frac{\rho^2}{1-\rho} = \frac{\lambda^2}{\mu(\mu-\lambda)}.$$

Tiempo medio de permanencia

W mide el tiempo desde que una solicitud llega hasta que sale. W_q mide solo el tiempo que espera en la fila. Como la cola es ilimitada, todas las llegadas entran al sistema y la tasa efectiva es λ. Por la ley de Little, $L = \lambda W$ y $L_q = \lambda W_q$.

$$W = \frac{L}{\lambda} = \frac{1}{\mu - \lambda},$$

$$W_q = \frac{L_q}{\lambda} = \frac{\lambda}{\mu(\mu-\lambda)} = \frac{\rho}{\mu - \lambda}.$$

Por qué la latencia crece tan rápido

$$W = \frac{1}{\mu(1-\rho)}$$

El tiempo medio de servicio es $1/\mu$. La siguiente tabla expresa el tiempo total de permanencia W como múltiplo de ese tiempo $\frac{W}{1/\mu} = \frac{1}{1-\rho}$.

ρ	W/(1/μ)
0.50	2 veces
0.80	5 veces
0.90	10 veces
0.95	20 veces

Por qué la latencia crece tan rápido

Por ejemplo, con $\rho = 0.95$, el tiempo medio total es 20 veces el tiempo de servicio. De ese total, 19 veces corresponden a la espera en la fila, pues $W_q = W - 1/\mu$. El servicio no se vuelve más lento. El aumento se debe a la espera.

> El modelo es estable cuando $\rho < 1$. Al acercarse ρ a 1, el factor $1/(1-\rho)$ crece rápidamente y queda menos margen para variaciones en la carga.

Ejemplo $M/M/1$: puerta de enlace

Considere una puerta de enlace que recibe solicitudes y las envía a un único servidor.

Modele las llegadas como un proceso de Poisson y los tiempos de servicio como exponenciales e independientes. Suponga que $\lambda = 125\ \text{solicitudes}/\text{s}$ y que el tiempo medio de servicio es $1/\mu = 2\ \text{ms}$.

Preguntas

1. Calcule la tasa media de servicio μ y la utilización ρ. Determine si el sistema es estable.
2. Calcule el tiempo medio de permanencia W y el tiempo medio de espera W_q.
3. Calcule el número medio de solicitudes en el sistema L y en la fila L_q. Interprete los resultados.

Ejemplo $M/M/1$: respuestas

Tasa media de servicio

$$\mu = \frac{1}{\mathbb{E}[S]} = \frac{1}{2\ \text{ms}} = 500\ \text{solicitudes/s}.$$

Utilización y estabilidad

$$\rho = \frac{\lambda}{\mu} = \frac{125}{500} = 0.25 < 1.$$

El sistema es estable porque $\rho < 1$.

Ejemplo $M/M/1$: respuestas de tiempo

W mide el tiempo desde la llegada hasta la salida. W_q mide solo la espera en la fila.

Permanencia media en el sistema

$$W = \frac{1}{\mu - \lambda} = \frac{1}{500 - 125}\ \mathrm{s} = 2.667\ \mathrm{ms}.$$

Espera media en la fila

$$W_q = \frac{\lambda}{\mu(\mu - \lambda)} = \frac{125}{500(500 - 125)}\ \mathrm{s} = 0.667\ \mathrm{ms}.$$

Ejemplo $M/M/1$: respuestas de cantidad

Por la ley de Little, $L = \lambda W$ y $L_q = \lambda W_q$:

$$L = \lambda W = (125 \text{ solicitudes/s})(0.002667 \text{ s}) = 0.333 \text{ solicitudes},$$
$$L_q = \lambda W_q = (125 \text{ solicitudes/s})(0.000667 \text{ s}) = 0.083 \text{ solicitudes}.$$

En promedio, cada solicitud permanece 2.667 ms en el sistema, incluidos 0.667 ms de espera y 2 ms de servicio. L y L_q son promedios temporales, por eso pueden ser menores que una solicitud.

Capacidad finita: $M/M/1/K$

K es el número máximo de solicitudes **en el sistema**, incluyendo quien está en servicio.

Los estados son $0, 1, \ldots, K$. En estado K, una nueva solicitud es rechazada y no cambia el estado. En el estado 0, el sistema está vacío y el servidor ocioso. No hay una solicitud en servicio que pueda salir.

El balance entre vecinos sigue dando $\pi_n = \pi_0 \rho^n$, pero ahora la normalización tiene solo $K + 1$ términos. Aquí $\rho = \lambda/\mu$ compara la carga de solicitudes con la capacidad.

> Incluso con $\rho \geq 1$ **existe una distribución estacionaria** en esta cadena finita. Eso no garantiza una pérdida aceptable.

Capacidad finita: normalización

Balance. Igualando los flujos entre n y $n+1$: $\pi_n \lambda = \pi_{n+1} \mu$. Como $\lambda / \mu = \rho$, se obtiene $\pi_n = \rho^n \pi_0$.

Normalización. Las probabilidades suman uno:

$$1 = \pi_0 \sum_{n=0}^{K} \rho^n$$

Por tanto, para todo ρ:

$$\pi_n = \frac{\rho^n}{\sum_{k=0}^{K} \rho^k}$$

La distribución está truncada por la capacidad: los clientes que no entran no aparecen en estos estados.

Capacidad finita: suma geométrica

Sea $S = \sum_{n=0}^{K} \rho^n$. Restamos ρS, es decir, la misma suma multiplicada por ρ:

$$S = 1 + \rho + \cdots + \rho^K,$$
$$\rho S = \rho + \cdots + \rho^K + \rho^{K+1}.$$

Los términos $\rho, \ldots, \rho^K$ aparecen en ambas sumas y se cancelan:

$$S - \rho S = 1 - \rho^{K+1}$$

Si $\rho \neq 1$, despejamos $S = \dfrac{1 - \rho^{K+1}}{1 - \rho}$.

Capacidad finita: distribución

Como $\pi_n = \rho^n / S$, para $\rho \neq 1$:

$$\pi_n = \frac{(1-\rho)\rho^n}{1-\rho^{K+1}}$$

Si $\rho = 1$, cada término de S vale 1, luego $S = K+1$ y $\pi_n = \dfrac{1}{K+1}$.

La suma es finita, así que no se exige $\rho < 1$. En $M/M/1$, en cambio, la serie infinita solo converge si $\rho < 1$.

Si $\rho < 1$ y $K \to \infty$, entonces $\rho^{K+1} \to 0$ y $\pi_n \to (1-\rho)\rho^n$, la distribución estacionaria de $M/M/1$.

Sobrecarga: $\rho \geq 1$ en $M/M/1$ y en $M/M/1/K$

En $M/M/1$, la distribución estacionaria existe solo si $\rho < 1$.

Con $\rho \geq 1$	$M/M/1$	$M/M/1/K$
Distribución estacionaria	No existe	Existe
Tamaño de la fila	Crece sin límite	Nunca supera K
Llegadas con sistema lleno	Esperan	Se rechazan

Con capacidad finita, una llegada que encuentra el sistema lleno se rechaza y se produce **bloqueo**. Así, la tasa de solicitudes que llegan, λ, no coincide con la tasa que realmente entra al sistema, λ_{e}.

Bloqueo y tasa efectiva

El bloqueo P_{B} es la probabilidad de que el sistema esté a capacidad completa:

$$P_{\mathrm{B}} = \pi_K$$

Las llegadas de Poisson ven el sistema como en un instante cualquiera (*Poisson Arrivals See Time Averages*, PASTA). Por eso, P_{B} también es la fracción de llegadas rechazadas, y $1 - P_{\mathrm{B}}$ es la fracción que entra al sistema. Como las llegadas ofrecidas ocurren a tasa λ, la tasa admitida es:

$$\lambda_{\mathrm{e}} = \lambda(1 - P_{\mathrm{B}})$$

Las llegadas admitidas excluyen los rechazos y no forman necesariamente un proceso de Poisson.

Ejemplo: bloqueo con $\rho \geq 1$

Con $\rho = 1.2$ y $K = 3$, la probabilidad de bloqueo es $P_{\mathrm{B}} = \pi_3$:

$$P_{\mathrm{B}} = \pi_3 = \frac{\rho^3}{1 + \rho + \rho^2 + \rho^3} = \frac{1.728}{5.368} \approx 0.322$$

Con $\lambda = 12$ y $\mu = 10$ solicitudes/min, la tasa admitida es:

$$\lambda_{\mathrm{e}} = \lambda(1 - P_{\mathrm{B}}) \approx 8.14 \,\mathrm{solicitudes/min}$$

Aunque $\lambda > \mu$, la tasa admitida es menor que μ. La diferencia $\lambda - \lambda_{\mathrm{e}}$ corresponde a las solicitudes rechazadas.

> Que las medidas sean finitas no implica una pérdida aceptable. Esa valoración depende del SLA.

Tasa admitida y ocupación

En equilibrio, el número de solicitudes en el sistema no crece de forma sostenida, así que lo que entra debe salir. Entran las solicitudes admitidas, a tasa λ_{e}. Salen a tasa μ cuando el servidor está ocupado, lo que ocurre con probabilidad $1 - \pi_0$. Por tanto:

$$\lambda_{\mathrm{e}} = \mu(1 - \pi_0).$$

La ocupación real es $1 - \pi_0 = \lambda_{\mathrm{e}}/\mu$. No es necesariamente igual a la carga ofrecida λ/μ.

Medidas de los clientes admitidos

Para $\lambda_{\mathrm{e}} > 0$, las medidas de los clientes admitidos son:

$$L = \sum_{n=0}^{K} n\pi_n, \qquad L_q = L - (1 - \pi_0).$$

- L promedia n usando π_n como pesos: son las solicitudes medias en el sistema.
- Con el servidor ocupado hay una solicitud en servicio, y eso ocurre con probabilidad $1 - \pi_0$. Por eso L_q resta ese valor a L.

$$W = \frac{L}{\lambda_{\mathrm{e}}}, \qquad W_q = \frac{L_q}{\lambda_{\mathrm{e}}} = W - \frac{1}{\mu}.$$

- Se aplica la ley de Little a las solicitudes admitidas, que entran a tasa λ_{e}.
- El servicio medio es $1/\mu$. Se descuenta de W para obtener W_q.

Ejemplo bloqueo $M/M/1/K$

En una fila $M/M/1/K$, considere $\lambda = 8\ \mathrm{s}^{-1}$, $\mu = 10\ \mathrm{s}^{-1}$ y $K = 3$.

Carga ρ. Con $\rho = \lambda/\mu$:

$$\rho = \frac{8}{10} = 0.8$$

Bloqueo P_{B}. Con $P_{\mathrm{B}} = \pi_K = \dfrac{(1-\rho)\rho^K}{1-\rho^{K+1}}$:

$$P_{\mathrm{B}} = \frac{(0.2)(0.8)^3}{1-(0.8)^4} \approx 0.173442$$

Ejemplo bloqueo $M/M/1/K$: tasa admitida

Con $\lambda = 8\ \mathrm{s}^{-1}$ y $P_{\mathrm{B}} \approx 0.173442$:

Tasa admitida λ_{e}. Con $\lambda_{\mathrm{e}} = \lambda(1 - P_{\mathrm{B}})$:

$$\lambda_{\mathrm{e}} = 8(1 - 0.173442) \approx 6.6125\ \mathrm{s}^{-1}$$

Usar λ en lugar de λ_{e} incluye solicitudes rechazadas y subestima el tiempo $W = L/\lambda_{\mathrm{e}}$ de los clientes admitidos.

Ejemplo bloqueo $M/M/1/K$: distribución

Con $\rho = 0.8$ y $K = 3$:

Probabilidades π_n. Con $\pi_n = \dfrac{(1-\rho)\rho^n}{1-\rho^{K+1}}$:

$$\pi_n = \frac{(0.2)(0.8)^n}{0.5904}$$

Así, $\pi_0 \approx 0.338753$, $\pi_1 \approx 0.271003$, $\pi_2 \approx 0.216802$ y $\pi_3 \approx 0.173442$.

Número medio en el sistema L. Con $L = \sum_{n=0}^{K} n\pi_n$:

$$L = 0.271003 + 2(0.216802) + 3(0.173442) \approx 1.224932$$

Ejemplo bloqueo $M/M/1/K$: tiempos

Tiempo en el sistema W. Con $W = L/\lambda_{\mathrm{e}}$, por la ley de Little aplicada a los clientes admitidos:

$$W = \frac{1.224932}{6.6125} \approx 0.185246 \text{ s}$$

Tiempo de espera W_q. Con $W_q = W - 1/\mu$:

$$W_q = 0.185246 - 0.1 \approx 0.085246 \text{ s}$$

El tiempo W corresponde a clientes admitidos. El bloqueo se informa aparte, porque las solicitudes rechazadas no reciben servicio.

Ejemplo $M/M/1/K$: espacio de espera

Una puerta de enlace recibe paquetes con tasa $\lambda = 125$ paquetes/s, y su tiempo de servicio medio es 2 ms. Se modela como $M/M/1/K$, donde K incluye el paquete en servicio y $B = K - 1$ es el número de puestos de espera. Se pide:

1. Calcule μ y ρ.
2. Calcule P_{B} para $K = 9$, $K = 10$ y $K = 14$.
3. Determine el menor K con $P_{\mathrm{B}} \leq 10^{-6}$ (un paquete perdido por millón) y el número de puestos de espera correspondiente.

Ejemplo $M/M/1/K$: tasa y carga

Tasa de servicio μ. Con $\mu = 1/\mathbb{E}[S]$:

$$\mu = \frac{1}{2\ \text{ms}} = 500\ \text{paquetes/s}$$

Carga ρ. Con $\rho = \lambda/\mu$:

$$\rho = \frac{125}{500} = 0.25$$

Como $\rho < 1$, la carga ofrecida es menor que la capacidad. Aun así, una capacidad finita produce pérdidas.

Ejemplo $M/M/1/K$: bloqueo

Con $\rho = 0.25$, la probabilidad de bloqueo es $P_{\mathrm{B}} = \pi_K$:

$$P_{\mathrm{B}} = \pi_K = \frac{(1-\rho)\rho^K}{1-\rho^{K+1}} = \frac{0.75\,(0.25)^K}{1-(0.25)^{K+1}}$$

Con $B = K - 1$ puestos de espera, para cada capacidad:

$$K = 9\ (B = 8): \quad P_{\mathrm{B}} = \frac{0.75(0.25)^9}{1-(0.25)^{10}} \approx 2.861 \times 10^{-6},$$

$$K = 10\ (B = 9): \quad P_{\mathrm{B}} = \frac{0.75(0.25)^{10}}{1-(0.25)^{11}} \approx 7.153 \times 10^{-7},$$

$$K = 14\ (B = 13): \quad P_{\mathrm{B}} = \frac{0.75(0.25)^{14}}{1-(0.25)^{15}} \approx 2.794 \times 10^{-9}.$$

Ejemplo $M/M/1/K$: capacidad

Para $K = 9$, $P_{\mathrm{B}} \approx 2.861 \times 10^{-6} > 10^{-6}$. Para $K = 10$, $P_{\mathrm{B}} \approx 7.153 \times 10^{-7} \leq 10^{-6}$.

Capacidad K. Se elige el menor K con $P_{\mathrm{B}} = \pi_K \leq 10^{-6}$:

$$K = 10$$

Puestos de espera B. Con $B = K - 1$, porque el paquete en servicio ocupa un lugar:

$$B = 10 - 1 = 9$$

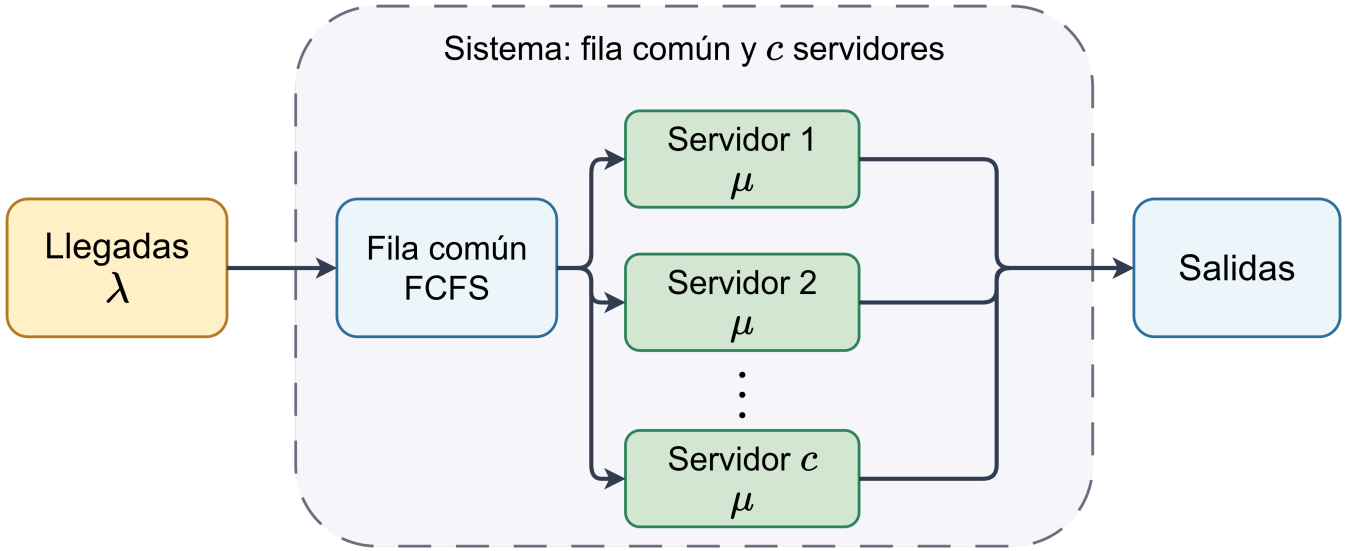
Varios servidores: $M/M/c$

> Con un servidor, una solicitud espera si el servidor está ocupado. Con c servidores, espera solo si los c están ocupados.

Un modelo $M/M/c$ tiene una fila común y c servidores idénticos. Las llegadas siguen un proceso de Poisson con tasa λ, y cada servidor atiende con tiempos exponenciales de media $1/\mu$.

En la notación de Kendall, la capacidad y la población son ilimitadas y la disciplina es FCFS: $M/M/c/\infty/\infty/\mathrm{FCFS}$.

Modelo $M/M/c$



Una solicitud entra a servicio en cuanto queda libre algún servidor. Si los c servidores están ocupados, la solicitud espera en la fila común.

Tasa total de salida

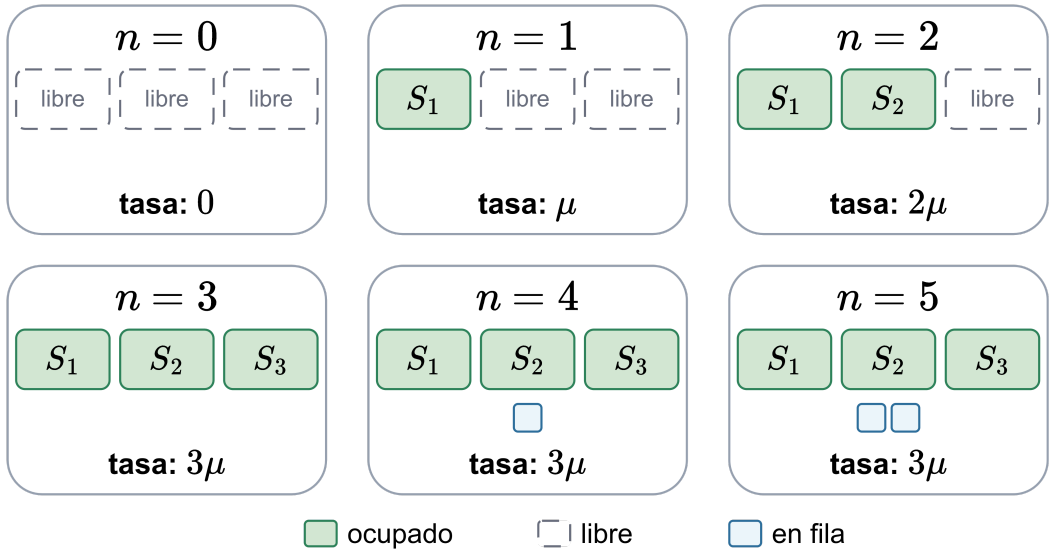
La tasa total de salida es la rapidez con que el sistema completa servicios. Cada servidor ocupado completa servicios a tasa μ, así que la tasa total suma μ por cada **servidor ocupado**:

$$\text{tasa total de salida} = \min(n, c)\,\mu$$

Aquí n es el número de solicitudes en el sistema, y $\min(n, c)$ es el número de servidores ocupados.

- Si $n < c$, hay $c - n$ servidores libres y ninguna solicitud espera.
- Si $n \geq c$, los c servidores están ocupados. La tasa se mantiene en $c\mu$, y las solicitudes adicionales forman fila.

Servidores ocupados según n



Con $c = 3$, cada recuadro muestra los servidores ocupados, las solicitudes en fila y la tasa total de salida. A partir de $n = 3$, la tasa deja de crecer, pero la fila sí aumenta.

Ejemplo de tasa total de salida

- Dado: $c = 3$, $\mu = 4$ por unidad de tiempo y $n = 5$.
- Fórmula: $\min(n, c)\,\mu$.
- Sustitución: $\min(5, 3) \cdot 4 = 3 \cdot 4$.
- Resultado: 12 por unidad de tiempo, con $5 - 3 = 2$ solicitudes en fila.

Con $n = 2$, en cambio, la tasa es $2 \cdot 4 = 8$ por unidad de tiempo, y ninguna solicitud espera.

Agregar solicitudes cuando $n \geq c$ no aumenta la tasa de salida. Solo aumenta la fila.

Tráfico ofrecido a

Cada solicitud necesita en promedio $1/\mu$ unidades de tiempo de un servidor. Si llegan λ solicitudes por unidad de tiempo, el trabajo que llega se mide con el tráfico ofrecido:

$$a = \frac{\lambda}{\mu}$$

Al dividir, las unidades de tiempo se cancelan y a cuenta servidores. Se mide en Erlangs: 1 Erlang equivale a un servidor ocupado todo el tiempo.

- Dado: $\lambda = 6$ y $\mu = 4$, por unidad de tiempo.
- Sustitución: $a = 6/4$.
- Resultado: $a = 1.5$ Erlangs.

Qué significa a con varios servidores

Con $c = 1$

- $a = 1.5$ supera la capacidad.
- La carga pide más servidores de los que hay.
- La fila crece sin límite.

Con $c = 2$

- $a = 1.5$ cabe en la capacidad.
- Sobran 0.5 servidores.
- La fila no crece sin límite.

a no cambia con c: es la carga. Lo que cambia es cuántos servidores hay para atenderla.

Por eso, la estabilidad exige $a < c$.

Carga por servidor ρ

La carga por servidor reparte el tráfico entre los c servidores:

$$\rho = \frac{a}{c} = \frac{\lambda}{c\mu}$$

Un servidor ($M/M/1$)

$\rho = \lambda/\mu$ es la fracción de tiempo que el servidor está ocupado.

Varios servidores ($M/M/c$)

$\rho = \lambda/(c\mu)$ es la fracción de tiempo que, en promedio, ocupa cada servidor.

Con $c = 1$, ambas fórmulas coinciden. Con $c = 2$ y $a = 1.5$, $\rho = 0.75$: cada servidor está ocupado el 75% del tiempo.

Condición de estabilidad $\lambda < c\mu$

La fila tiene régimen estable si:

$$\boxed{\lambda < c\mu \quad \Longleftrightarrow \quad \rho < 1}$$

Para ver de dónde sale, se considera la fila cuando los c servidores están ocupados. Cada llegada suma una solicitud al sistema. Cada servidor ocupado completa μ solicitudes por unidad de tiempo, así que la salida total es $c\mu$. El número de solicitudes cambia en promedio a razón de

$$\lambda - c\mu \text{ solicitudes por unidad de tiempo}$$

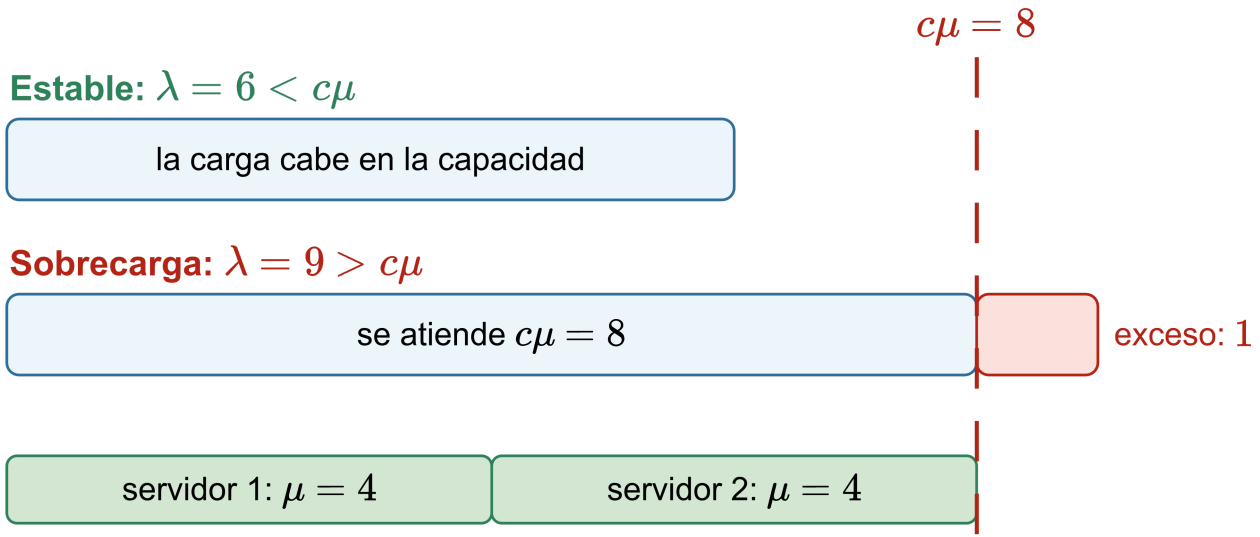
Si $\lambda > c\mu$, la fila crece sin límite. Si $\lambda < c\mu$, sube y baja, pero no crece sin límite.

No es $\lambda < \mu$

> Usar μ en lugar de $c\mu$ es un error frecuente. Con $c = 2$ y $\mu = 4$, la condición $\lambda < \mu$ exige $\lambda < 4$. Con $\lambda = 6$, esa regla rechaza un sistema que sí es estable.

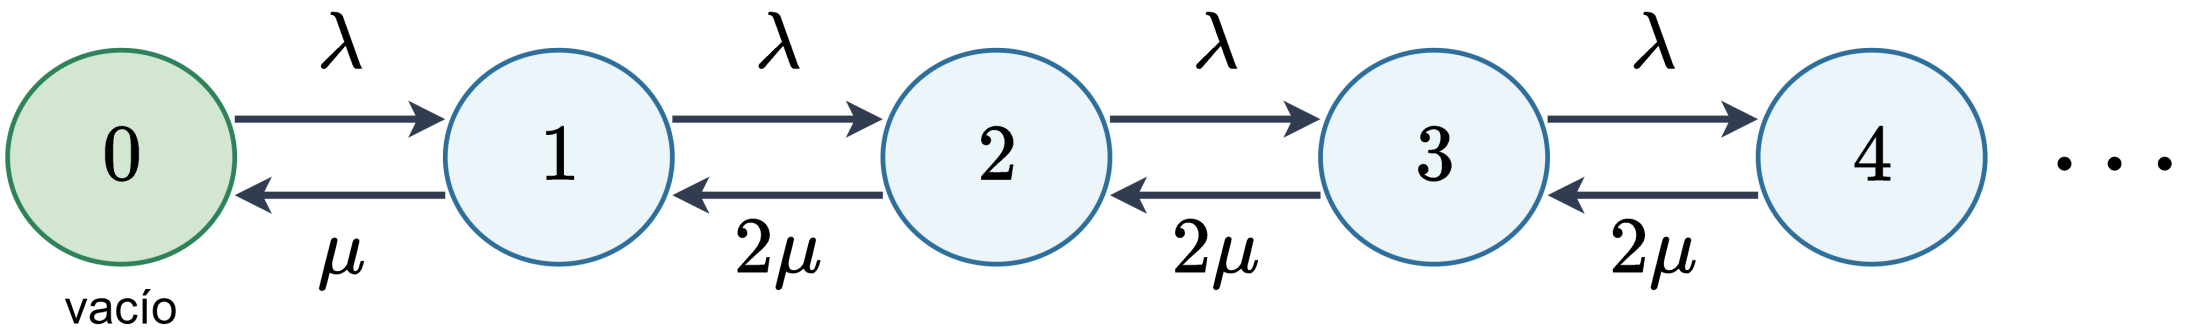
La condición correcta es $\lambda < c\mu = 8$. Con $\lambda = 6$ se cumple, aunque la carga supera la tasa de un solo servidor.

Capacidad total frente a la carga



La figura compara la tasa de llegada con la capacidad total, $c\mu = 8$, que son dos servidores con $\mu = 4$ cada uno. Con $\lambda = 6$, toda la carga se atiende. Con $\lambda = 9$, el sistema atiende como máximo 8, y el exceso de 1 por unidad de tiempo se acumula en la fila.

Estados y cadena de nacimiento y muerte



Cada llegada sube el estado n en una unidad, a tasa λ. Cada salida lo baja, a tasa $\min(n, c)\mu$. Con $c = 2$, la tasa de bajada crece porque hay más servidores ocupados: con $n = 1$ trabaja un servidor (μ), con $n = 2$ trabajan los dos (2μ). Desde $n = 2$, los dos servidores están ocupados, así que la tasa se queda en 2μ, aunque lleguen más solicitudes.

Balance entre estados vecinos

En un proceso de nacimiento y muerte, λ_n es la tasa de subida desde el estado n, y μ_n es la tasa de bajada desde n. En $M/M/c$, $\lambda_n = \lambda$ y $\mu_n = \min(n, c)\mu$.

En equilibrio, el flujo que sube de n a $n+1$ iguala al flujo que baja de $n+1$ a n:

$$\pi_n \lambda_n = \pi_{n+1} \mu_{n+1}$$

Cada flujo es la probabilidad del estado de origen por su tasa de transición. Con este balance, π_{n+1} se obtiene a partir de π_n.

Distribución para $n < c$

Para $n < c$, la tasa de bajada desde n es $n\mu$, porque hay n servidores ocupados. El balance entre $n-1$ y n da:

$$\pi_n = \frac{\lambda}{n\mu}\,\pi_{n-1} = \frac{a}{n}\,\pi_{n-1}$$

Repitiendo el paso desde π_0 hasta n:

$$\pi_n = \frac{a}{1}\cdot\frac{a}{2}\cdots\frac{a}{n}\,\pi_0 = \frac{a^n}{n!}\,\pi_0$$

Origen del factorial en π_n

Cada paso del balance aporta un factor a/k, con $k = 1, \ldots, n$. El factorial no viene de la normalización: es el producto de los denominadores,

$$1 \cdot 2 \cdots n = n!$$

- Dado: $c = 3$ y $a = 1.5$.
- Sustitución: $\pi_2 = \frac{1.5^2}{2!}\,\pi_0$.
- Resultado: $\pi_2 = 1.125\,\pi_0$.

Distribución para $n \geq c$

Desde $n = c$, todos los servidores están ocupados y la tasa de bajada se queda en $c\mu$. Cada solicitud adicional multiplica la probabilidad por $\rho = \lambda/(c\mu)$, así que:

$$\pi_n = \pi_0 \, \frac{a^c}{c!} \, \rho^{\,n-c} \qquad (n \geq c)$$

Con $\rho < 1$, las probabilidades decrecen de forma geométrica al crecer n.

- Dado: $c = 2$, $a = 1.5$ y $\rho = 0.75$.
- Sustitución: $\pi_3 = \frac{1.5^2}{2!} \cdot 0.75 \, \pi_0$.
- Resultado: $\pi_3 = 0.84375 \, \pi_0$.

Normalización y π_0

Las probabilidades deben sumar 1. Para $n < c$, $\pi_n = \frac{a^n}{n!}\,\pi_0$. Para $n \geq c$, $\pi_n = \pi_0\,\frac{a^c}{c!}\,\rho^{\,n-c}$. Con el cambio $k = n - c$, el exponente $n - c$ pasa a ser k, y la suma empieza en $k = 0$ porque $n = c$ corresponde a $k = 0$:

$$\sum_{n \geq c} \pi_n = \pi_0\,\frac{a^c}{c!}\sum_{k=0}^{\infty}\rho^k$$

Sumando los estados $n < c$ y $n \geq c$, e igualando a 1:

$$\pi_0\left[\sum_{n=0}^{c-1}\frac{a^n}{n!} + \frac{a^c}{c!}\sum_{k=0}^{\infty}\rho^k\right] = 1$$

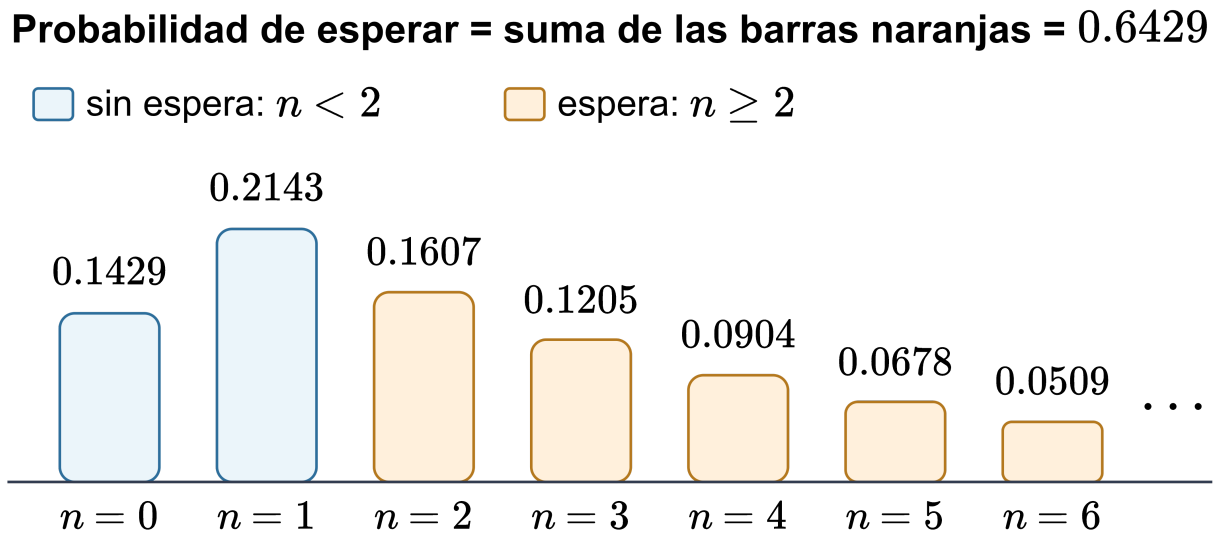
Serie geométrica de la normalización

Si $\rho \geq 1$, la suma diverge y no hay distribución estacionaria. Si $\rho < 1$, esta converge a $\sum_{k=0}^{\infty} \rho^k = \frac{1}{1-\rho}$
Sustituyendo en la fórmula anterior:

$$\pi_0 = \left[\sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!} \frac{1}{1-\rho} \right]^{-1}$$

Habiendo obtenido π_0, luego es posible obtener cualquier probabilidad π_n.

Distribución de n con $c = 2$



Con $c = 2$ y $a = 1.5$, las barras naranjas son los estados en que la solicitud que llega encuentra los dos servidores ocupados. Su suma es la probabilidad de esperar.

Probabilidad de esperar: Erlang C

Sea T_q el tiempo de espera de una solicitud. Una solicitud espera si, al llegar, encuentra c o más solicitudes en el sistema. Como las llegadas son Poisson, ven el sistema con las probabilidades π_n (propiedad PASTA). Por tanto:

$$C(c,a) = P(T_q > 0) = \sum_{n=c}^{\infty} \pi_n = \frac{a^c}{c!}\,\frac{1}{1-\rho}\,\pi_0$$

La última igualdad usa la suma geométrica de $\rho^{\,n-c}$ con $n \geq c$. $C(c,a)$ es la fórmula de Erlang C.

Ejemplo $M/M/2$

Se toma la hora como unidad de tiempo, con $\lambda = 6$, $c = 2$ y $\mu = 4$ por hora. Primero se calculan el tráfico ofrecido y la carga por servidor:

$$a = \frac{6}{4} = 1.5, \qquad \rho = \frac{6}{8} = 0.75$$

Con esos valores, π_0 se obtiene de la normalización:

$$\pi_0 = \left[1 + 1.5 + \frac{1.5^2}{2(1 - 0.75)}\right]^{-1} = \frac{1}{7}$$

La probabilidad de esperar es:

$$C(2, 1.5) = \frac{1.5^2}{2(1 - 0.75)}\,\frac{1}{7} = \frac{4.5}{7} \approx 0.6429$$

Espera promedio sobre todas las solicitudes

Sea T_q el tiempo que una solicitud pasa en la fila antes de ser atendida. Con $c = 2$, $\lambda = 6$ y $\mu = 4$ por hora, $P(T_q > 0) = C(2, 1.5) = \frac{9}{14} \approx 0.6429$.

De cada 100 solicitudes, en promedio 64.29 encuentran los dos servidores ocupados y esperan. Las otras 35.71 encuentran un servidor libre y tienen $T_q = 0$.

W_q es el promedio de T_q sobre las 100. Las que no esperan aportan cero a la suma, pero sí cuentan en el promedio.

Espera media de quienes esperan

La espera media de quienes esperan depende de qué tan rápido se vacía la fila.

Mientras los c servidores están ocupados, la fila pierde en promedio $c\mu - \lambda$ solicitudes por unidad de tiempo. Con $c = 2$, $\lambda = 6$ y $\mu = 4$ por hora, eso son $8 - 6 = 2$ solicitudes por hora.

Por intuición, la espera de quien espera es del orden de $\frac{1}{c\mu - \lambda} = 0.5\ \mathrm{h}$. Cuanta más capacidad libre hay, más rápido se vacía la fila y más corta es la espera.

De Erlang C a W_q

Se separan las solicitudes según si esperan. Cada grupo aporta su fracción multiplicada por su espera media:

Grupo	Fracción	Espera media	Aporte a W_q
No espera	0.3571	$0\ \text{h}$	$0\ \text{h}$
Espera	0.6429	$0.5\ \text{h}$	$0.3214\ \text{h}$

Es la ley de la esperanza total:

$$W_q = P(T_q = 0) \cdot 0 + P(T_q > 0) \cdot E[T_q \mid T_q > 0]$$

Con $P(T_q > 0) = C(c, a)$ y $E[T_q \mid T_q > 0] = \frac{1}{c\mu - \lambda}$:

$$W_q = \frac{9}{14} \cdot \frac{1}{2}\ \text{h} = \frac{9}{28}\ \text{h} \approx 0.3214\ \text{h}$$

Métricas de $M/M/c$

Con W_q calculado, el tiempo medio en el sistema suma el servicio:

$$W = W_q + \frac{1}{\mu}$$

En $M/M/c$ no hay bloqueo, así que la tasa admitida es λ. La ley de Little da:

$$L_q = \lambda W_q, \qquad L = \lambda W$$

Completar el ejemplo $M/M/2$

Con $W_q = C(c,a)/(c\mu - \lambda)$ y $c\mu - \lambda = 8 - 6 = 2\ \mathrm{h}^{-1}$:

$$W_q = \frac{9/14}{8-6}\ \mathrm{h} = \frac{9}{28}\ \mathrm{h} \approx 0.3214\ \mathrm{h}$$

Con $W = W_q + 1/\mu$:

$$W = \left(\frac{9}{28} + \frac{1}{4}\right)\mathrm{h} = \frac{4}{7}\ \mathrm{h} \approx 0.5714\ \mathrm{h}$$

Con $L_q = \lambda W_q$ y $L = \lambda W$:

$$L_q = 6\left(\frac{9}{28}\right) \approx 1.9286 \qquad L = 6\left(\frac{4}{7}\right) \approx 3.4286$$

Las unidades ayudan a detectar errores. $C(c,a)$ es adimensional y $c\mu - \lambda$ está en h^{-1}, así que W_q queda en horas.

Qué significa Erlang C

Con $c = 2$, el 64.29% de las solicitudes encuentra los dos servidores ocupados y espera. El promedio $W_q = 0.3214\ \mathrm{h}$ incluye también a quienes no esperan.

Una solicitud que espera tiene, en promedio, una espera de $1/(c\mu - \lambda)$, si la disciplina es FCFS y los servicios son exponenciales:

$$E[T_q \mid T_q > 0] = \frac{1}{c\mu - \lambda} = 0.5\ \mathrm{h}$$

Comprobación: $C(2, 1.5)\, E[T_q \mid T_q > 0] = \frac{9}{14} \cdot 0.5\ \mathrm{h} = \frac{9}{28}\ \mathrm{h} = W_q$.

La probabilidad de esperar y el tiempo medio entre quienes esperan describen resultados distintos. Según el objetivo del servicio, puede interesar cualquiera de los dos.

Un servidor rápido no equivale a c servidores

Un servidor de tasa $c\mu$

- Servicio medio por solicitud: $1/(c\mu) = 0.125$ h.
- $P(T_q > 0) = \rho = 0.75$.
- $W_q = 0.375$ h.

c servidores de tasa μ

- Servicio medio por solicitud: $1/\mu = 0.25$ h.
- $P(T_q > 0) = C(2, 1.5) \approx 0.6429$.
- $W_q \approx 0.3214$ h.

Con $c = 2$, $\lambda = 6$ y $\mu = 4$ por hora, el modelo de un servidor rápido sobrestima la espera. Con dos servidores, una solicitud espera solo si ambos están ocupados. Con un solo servidor, espera cada vez que el único servidor está ocupado.

Elegir un modelo según el sistema

Dos preguntas sobre el sistema real orientan la elección: cuántos servidores atienden y si hay un límite de solicitudes dentro del sistema.

	Sin límite de capacidad	**Capacidad total K**
Un servidor	$M/M/1$	$M/M/1/K$
c servidores	$M/M/c$	$M/M/c/K$

Los tres modelos estudiados son ejemplos de una familia más amplia. El cuarto caso, $M/M/c/K$, combina ambos efectos y también existe. Otros modelos cambian las letras de Kendall: por ejemplo, $M/G/1$ admite tiempos de servicio que no son exponenciales.

Cuándo usar $M/M/1$, $M/M/1/K$ y $M/M/c$

Modelo	Se usa cuando	Ejemplo
$M/M/1$	Atiende un solo servidor y el espacio de espera es tan amplio que casi no se rechaza nada. Interesa el tiempo de respuesta.	Una interfaz con un procesador y memoria amplia.
$M/M/1/K$	Atiende un solo servidor y el espacio es limitado: con el sistema lleno, la solicitud se pierde. Interesa la fracción perdida y el espacio necesario.	Una puerta de enlace con un búfer de K paquetes.
$M/M/c$	Atienden c servidores iguales desde una fila común. Interesa la espera y cuántos servidores hacen falta.	Un centro de llamadas con c agentes.

En los tres, la letra M supone llegadas Poisson y servicio exponencial. Si los datos no se ajustan, conviene otro modelo de la familia o una simulación.

Acuerdo de nivel de servicio (SLA)

> **SLA** (*Service Level Agreement*): acuerdo escrito entre quien presta un servicio y quien lo usa, que fija metas medibles de calidad.

Un SLA fija tres cosas:

- **Métrica:** lo que se mide, como el tiempo de atención.
- **Umbral:** el valor que debe respetarse.
- **Cobertura:** qué parte de las solicitudes debe respetar el umbral.

Más información: Acuerdo de nivel de servicio (Wikipedia).

Ejemplo de SLA

- Meta: el 80% de las llamadas se atiende en $20\ \mathrm{s}$ o menos.
- Métrica: tiempo de atención T.
- Umbral: $T \leq 20\ \mathrm{s}$.
- Cobertura: el 80% de las llamadas.

Un SLA sobre el tiempo medio y otro sobre el 95% de las solicitudes no exigen lo mismo. El segundo pide que casi todas respeten el umbral.

Diseñar para un objetivo medio de latencia

Sea $w_{\max}$ el tiempo medio máximo que permite el SLA. En $M/M/1$, $W = \frac{1}{\mu - \lambda}$, así que se exige $W \leq w_{\max}$. Al despejar μ:

$$\mu - \lambda \geq \frac{1}{w_{\max}} \quad \Longrightarrow \quad \mu \geq \lambda + \frac{1}{w_{\max}}$$

La capacidad debe superar la carga en al menos $1/w_{\max}$.

Ejemplo: tasa de servicio para un objetivo medio

- Dado: $\lambda = 18$ solicitudes $\min^{-1}$ y $w_{\max} = 4$ s $= \frac{1}{15}$ min.
- Sustitución: $\mu \geq 18 + 15$.
- Resultado: $\mu \geq 33$ solicitudes $\min^{-1}$, es decir, un servicio medio de a lo más $60/33 = 1.818$ s.

Con $\mu = 33$ solicitudes $\min^{-1}$, el tiempo medio es exactamente 4 s. El requisito se aplica a la media: $w_{\max}$ no impide que algunas solicitudes tarden más, solo que el promedio no supere ese valor.

Antes de usar la fórmula, se verifica la estabilidad. En $M/M/1$ debe cumplirse $\lambda < \mu$, aquí $18 < 33$. Si $\mu \leq \lambda$, la fila crece sin límite y el tiempo medio no es finito. En $M/M/c$, la condición es $\lambda < c\mu$.

Un promedio no es un percentil

Sea $W_{\text{solicitud}}$ el tiempo de respuesta de una solicitud. Un SLA puede exigir un promedio o un percentil, y son exigencias distintas.

Promedio

- Exigencia: $E[W_{\text{solicitud}}] \leq w$.
- Mide el tiempo típico de una solicitud.

Percentil p

- Exigencia: $P(W_{\text{solicitud}} \leq w) \geq p$.
- Mide el tiempo que una fracción p de las solicitudes no excede.

Cumplir el promedio no garantiza cumplir el percentil.

Tiempo de respuesta en $M/M/1$

En $M/M/1$ estable con disciplina FCFS, el tiempo de respuesta $W_{\text{solicitud}}$ es exponencial de tasa $\mu - \lambda$. Por eso:

$$E[W_{\text{solicitud}}] = \frac{1}{\mu - \lambda} \qquad P(W_{\text{solicitud}} > w) = e^{-(\mu-\lambda)w}$$

La primera fórmula permite verificar una exigencia sobre el promedio. La segunda, una exigencia sobre un percentil.

Percentil 95 en $M/M/1$

El percentil 95, w_{95}, se excede con probabilidad 0.05.

$$e^{-(\mu-\lambda)w_{95}} = 0.05 \quad \Longrightarrow \quad w_{95} = \frac{\ln 20}{\mu - \lambda}$$

- Dado: $\lambda = 18\ \text{min}^{-1}$ y $\mu = 24\ \text{min}^{-1}$, así que $\mu - \lambda = 6\ \text{min}^{-1}$.
- Promedio: $\frac{1}{6}\ \text{min} = 10\ \text{s}$.
- Percentil 95: $\frac{\ln 20}{6}\ \text{min} \approx 29.96\ \text{s}$.

El 5% de las solicitudes tarda más de $29.96\ \text{s}$, casi el triple del promedio.

Diseño con varios servidores

En $M/M/1$ se despejó μ. En $M/M/c$, c es un número entero, así que se prueban valores crecientes hasta cumplir el requisito:

1. Partir del menor c con $\lambda < c\mu$.
2. Calcular $C(c, a)$ y W_q, y compararlos con el requisito.
3. Si no se cumple, aumentar c. Al final, revisar el costo.

> - Dado: $\lambda = 6$ y $\mu = 4$ por hora, con $W_q \leq 0.1\ \text{h}$.
> - Con $c = 2$: $W_q = 0.3214\ \text{h}$, no cumple. Con $c = 3$: $W_q = 0.0395\ \text{h}$, cumple.

Con $c = 2$ el sistema es estable, pero no cumple. La estabilidad no mide la calidad.

Ejercicio: dimensionar un servicio

Una interfaz recibe solicitudes Poisson a tasa $\lambda = 18\ \text{min}^{-1}$. Un servidor atiende en tiempo exponencial medio de $2.5\ \text{s}$.

1. Justifique el modelo.
2. Calcule μ y ρ.
3. Determine L, L_q, W y W_q.
4. Si se exige $W \leq 4\ \text{s}$, ¿cumple?
5. Indique una limitación del modelo.

Solución del ejercicio

Modelo. Llegadas Poisson, un servidor, servicio exponencial y sin rechazos: $M/M/1$.

$$\mu = \frac{60}{2.5} = 24\ \text{min}^{-1}, \qquad \rho = \frac{18}{24} = 0.75$$

$$L = \frac{18}{24-18} = 3, \qquad L_q = \frac{18^2}{24(24-18)} = 2.25$$

$$W = \frac{1}{24-18}\ \text{min} = 10\ \text{s}, \qquad W_q = W - \frac{1}{\mu} = 7.5\ \text{s}$$

Objetivo. No cumple $W \le 4$ s, porque $W = 10$ s. Se necesita $\mu \ge 18 + 15 = 33\ \text{min}^{-1}$.

Limitación. El modelo supone servicios exponenciales independientes de la carga.

¿Por qué estados de capacidad?

Los modelos anteriores suponen capacidad fija. Un servicio real puede estar en estado normal, degradado o de falla, y un solo valor para todo el servicio oculta esos cambios.

Por eso cada estado se trata por separado. Para no confundirlos con el número de solicitudes n de la fila, cada uno necesita una notación propia.

Notación para estados de capacidad

Los subíndices N, D y F identifican el estado de capacidad: normal, degradado y de falla. No son el n de π_n, λ_n y μ_n en la fila.

- π_N, π_D, π_F: probabilidades estacionarias, es decir, la fracción de tiempo en cada estado.
- μ_N, μ_D, μ_F: tasas de servicio en cada estado.
- W_N, W_D: tiempos medios de respuesta. En falla no hay servicio.

Promediar una métrica por estado

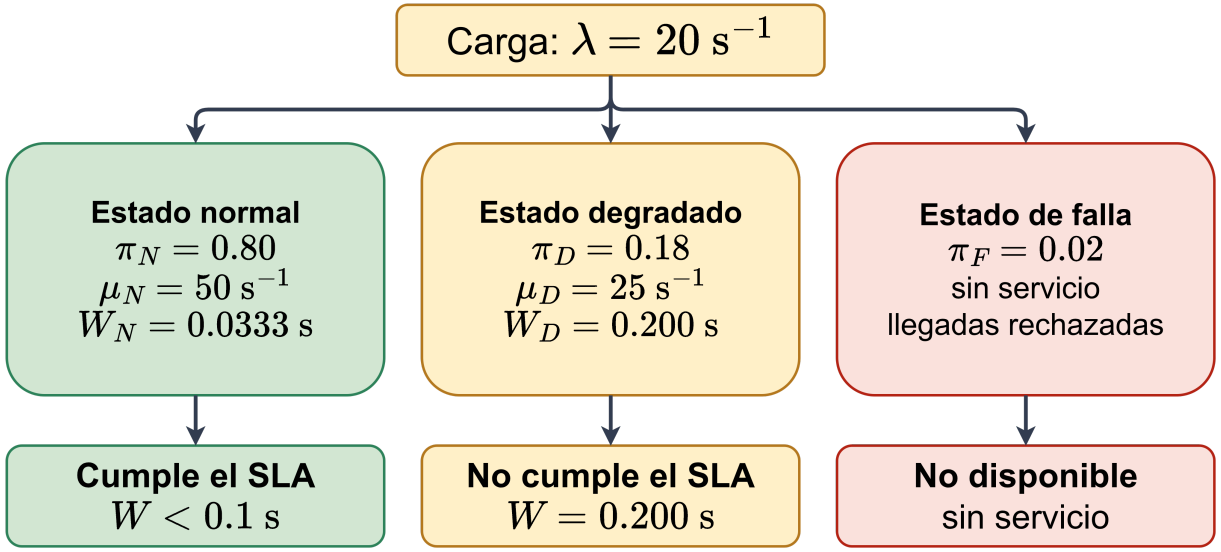
Cada estado da una respuesta distinta, y ninguna describe por sí sola lo que recibe el servicio. Por eso cada valor se pondera por la fracción de tiempo que el servicio pasa en su estado.

Para un estado i, π_i es esa fracción y r_i es la recompensa por unidad de tiempo, es decir, el valor de la métrica en ese estado:

$$\overline{r} = \sum_i \pi_i r_i$$

Para medir la fracción de tiempo en que se cumple un objetivo, se asigna $r_i = 1$ a los estados que lo cumplen y $r_i = 0$ a los demás.

La capacidad depende del estado



La figura sigue una misma carga, $\lambda = 20\ \text{solicitudes}\,\mathrm{s}^{-1}$, por los tres estados. Solo el normal cumple el objetivo: el degradado responde tarde y en falla no se atiende.

La disponibilidad dice cuánto tiempo ocupa cada estado, y las filas, qué experiencia recibe cada solicitud.

Ejemplo: servicio con tres estados

El servicio atiende $50\ \text{solicitudes}\,\text{s}^{-1}$ en estado normal y $25\ \text{solicitudes}\,\text{s}^{-1}$ en degradado. La carga es $20\ \text{solicitudes}\,\text{s}^{-1}$. Los cambios de estado son lentos, así que cada estado operativo es una fila $M/M/1$ en equilibrio, con $W = \frac{1}{\mu - \lambda}$:

$$W_N = \frac{1}{50 - 20} = 0.0333\ \text{s}, \qquad W_D = \frac{1}{25 - 20} = 0.2\ \text{s}$$

Los cambios entre estados se modelan con una cadena de Markov de tiempo continuo (CTMC). Su distribución estacionaria, es decir, la fracción de tiempo en cada estado, es:

$$(\pi_F, \pi_D, \pi_N) = (0.02,\ 0.18,\ 0.80)$$

Cumplimiento y conectividad

Si el SLA exige un tiempo medio menor que 0.1 s, solo el estado normal cumple: $W_N = 0.0333$ s, $W_D = 0.2$ s y en falla no hay servicio. Con $r_i = 1$ en los estados que cumplen y $r_i = 0$ en los demás:

$$A_{\text{SLA}} = \pi_F \cdot 0 + \pi_D \cdot 0 + \pi_N \cdot 1 = 0.80$$

La conectividad es la fracción de tiempo en que el servicio responde, en estado normal o degradado:

$$\pi_D + \pi_N = 0.98$$

Miden cosas distintas: el servicio responde casi siempre (0.98), pero cumple el SLA solo el 80% del tiempo.

Tiempo medio de respuesta y sus límites

Las solicitudes que llegan en falla se rechazan, así que solo cuentan los estados operativos. Si λ no depende del estado, se pondera por π_D y π_N y se normaliza por $\pi_D + \pi_N$:

$$\overline{W}_{\text{op}} \approx \frac{0.18(0.2) + 0.80(0.0333)}{0.98} = 0.0639\ \text{s}$$

Es una aproximación: supone que la fila alcanza su equilibrio antes de que cambie la capacidad. No vale si las solicitudes se acumulan entre estados ni si $\mu_D \leq \lambda$, pues entonces el estado degradado no tiene promedio estacionario. Un análisis exacto requiere una cadena conjunta o una simulación.

Ejercicio de diseño: comparar mejoras

Para el servicio de tres estados, compare dos cambios:

1. Mejorar la capacidad degradada de 25 a $40\ \mathrm{solicitudes\,s^{-1}}$.
2. Reducir π_D de 0.18 a 0.08, aumentando π_N de 0.80 a 0.90.

Para cada cambio, determine la conectividad, la fracción de tiempo que cumple el SLA y el promedio aproximado de respuesta. Justifique cuál conviene y declare los supuestos.

Ejercicio de diseño: resultados

Configuración	Conectividad	Fracción que cumple el SLA	$\overline{W}_{\text{op}}$
original	0.98	0.80	$0.0639\ \text{s}$
capacidad degradada de 40	0.98	0.98	$0.0364\ \text{s}$
menos degradación	0.98	0.90	$0.0469\ \text{s}$

Ambas alternativas mantienen la conectividad. La primera logra el mayor cumplimiento y el menor tiempo medio, porque el estado degradado también cumple $0.1\ \text{s}$.

La elección necesita además costos y evidencia de que las capacidades propuestas son alcanzables.

Referencias

1. J. F. Shortle, J. M. Thompson, D. Gross y C. M. Harris, *Fundamentals of Queueing Theory*, 5.ª ed., Wiley, 2018, capítulos 1 a 3 y secciones 7.7 y 9.3.
2. K. S. Trivedi, *Probability and Statistics with Reliability, Queuing, and Computer Science Applications*, 2.ª ed., Wiley, 2002, capítulos 8 y 9.
3. D. P. Bertsekas y R. G. Gallager, *Data Networks*, 2.ª ed., Prentice Hall, 1992, cap. 3.
4. J. M. Martínez, *Continuous Time Markov Chains*, material histórico TEL211, páginas 41 a 50.
5. L. A. Lizama, *Teoría de Colas TEL211*, material histórico USM. Kendall, Little y ejemplo de dimensionamiento del gateway.