TEL211

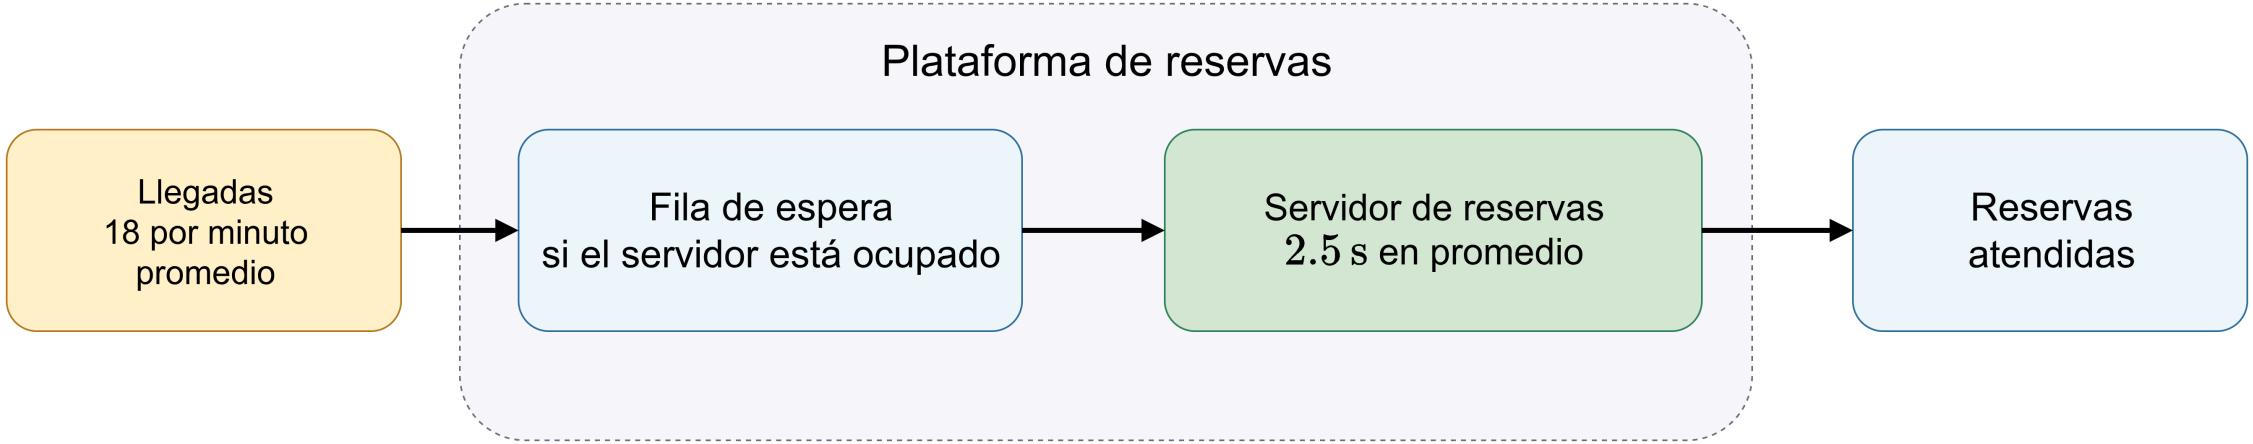
Disponibilidad y Rendimiento de Sistemas de Tecnologías de Información y Comunicaciones (TIC)

Teoría de filas: de la carga al tiempo de respuesta

Patricio Olivares R.
Universidad Técnica Federico Santa María

Un servicio puede estar disponible y responder tarde

En hora punta llegan $18\ \text{solicitudes}\,\text{min}^{-1}$ a una plataforma de reservas. Un servidor tarda, en promedio, $2.5\ \text{s}$ en atender cada solicitud.



Si el servidor está ocupado, la nueva solicitud espera. El servicio sigue disponible, pero la disponibilidad no indica cuánto demora cada respuesta.

¿Qué estudia la teoría de filas?

La teoría de filas estudia sistemas donde solicitudes llegan, esperan si los servidores están ocupados, reciben servicio y salen. Si no queda espacio, se rechazan.

Un modelo describe las llegadas, el espacio de espera, la capacidad de servicio y el orden de atención. Así permite estimar tiempos de respuesta, solicitudes acumuladas, utilización y bloqueo.

Qué observaremos bajo carga

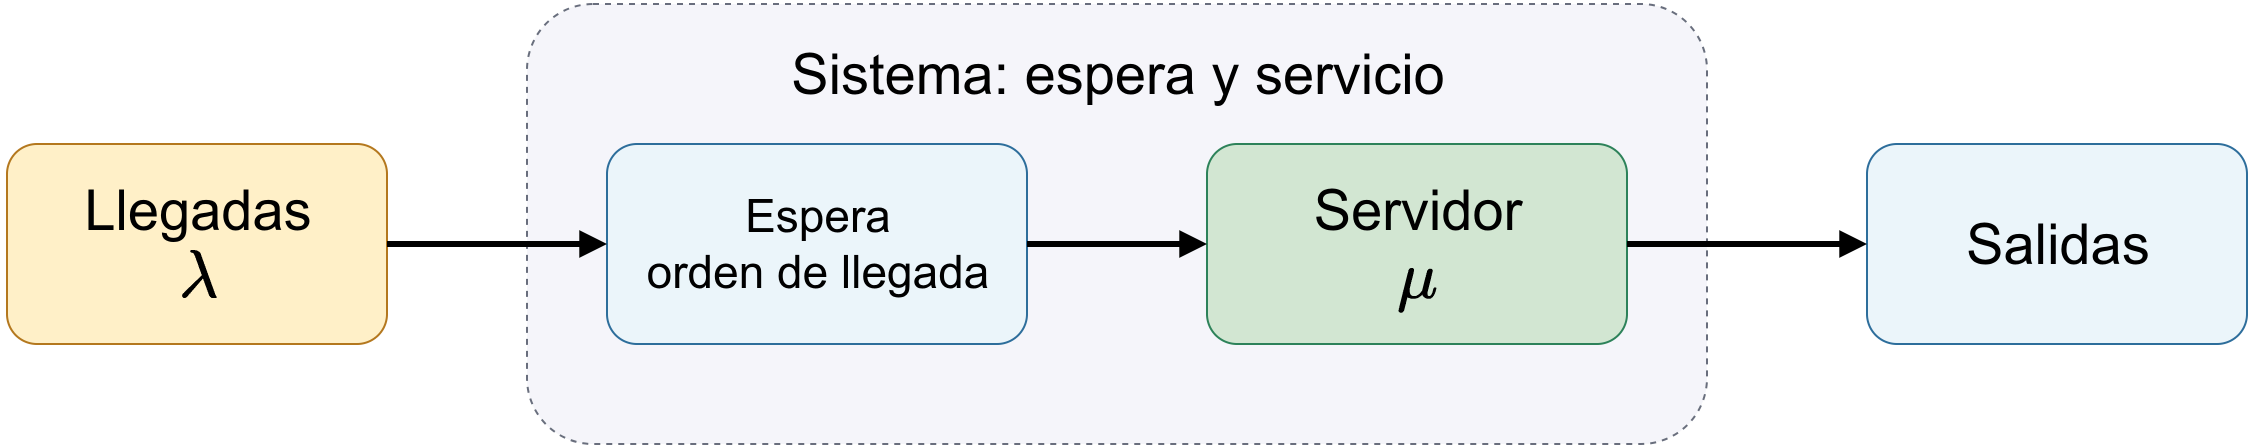
Pregunta	Medida
¿Cuánto tarda una solicitud, en promedio?	W (*waiting*): desde la admisión hasta la salida. W_q: solo la espera.
¿Cuántas solicitudes hay, en promedio?	L (*line*): en todo el sistema. L_q: solo en espera.
¿Qué fracción del tiempo está ocupado el servidor?	Utilización ρ
¿Qué probabilidad hay de rechazar una llegada?	Bloqueo P_{B} y tasa efectiva λ_{e}
¿Cuántos servidores satisfacen el objetivo?	Capacidad y latencia para un SLA

Magnitudes y frontera

Magnitud	Significado	Unidad típica
λ	tasa de llegada ofrecida	$\text{solicitudes}\,\text{s}^{-1}$
λ_{e}	tasa efectiva admitida	$\text{solicitudes}\,\text{s}^{-1}$
μ	tasa de servicio por servidor	$\text{solicitudes}\,\text{s}^{-1}$
L, L_q	número medio en sistema y en espera	solicitudes
W, W_q	tiempo medio en sistema y en espera	s
ρ	utilización: fracción de capacidad ocupada	adimensional
P_{B}	probabilidad de bloqueo	adimensional

Un acuerdo de nivel de servicio (SLA) fija el objetivo de latencia, bloqueo u otra métrica que se debe satisfacer.

Anatomía de una fila



La frontera del sistema incluye a quienes esperan y a quienes están en servicio. Una llegada puede entrar o ser rechazada si no queda espacio.

El tiempo de respuesta va desde la admisión hasta la salida. El tiempo de espera termina cuando comienza el servicio.

Llegadas y servicio en Kendall

A viene de *Arrival* y describe los tiempos entre llegadas. S viene de *Service* y describe los tiempos de servicio. Cada campo puede tomar uno de estos valores:

Valor	Significado
M	*Markovian*. La exponencial no tiene memoria. En A corresponde a llegadas Poisson y en S a servicio exponencial.
D	*Deterministic*. El tiempo entre llegadas o el tiempo de servicio es fijo.
G	*General*. Se permite otra distribución de probabilidad.

Servidores, capacidad, población y disciplina

Los campos restantes describen los recursos y las reglas del sistema:

Campo	Significado
c	Número de servidores en paralelo.
K	Capacidad máxima dentro del sistema, incluido quien recibe servicio.
N	*Number* de fuentes posibles de solicitudes.
D	*Discipline*, regla que decide quién sigue. FCFS (*First Come, First Served*) atiende en orden de llegada.

En los campos A o S, D significa *Deterministic*. Como último campo, D significa *Discipline*.

Notación

Los seis campos aparecen en este orden: $A/S/c/K/N/D$. El símbolo ∞ indica que la capacidad o la población no tienen límite.

Por ejemplo, $M/M/2/10/\infty/\mathrm{FCFS}$ describe llegadas Poisson, servicio exponencial, dos servidores, capacidad total de diez, población ilimitada y atención en orden de llegada.

Aquí $N(t)$ representa el número de solicitudes dentro del sistema en el instante t. En Kendall, N representa la población fuente.

Ejemplos de modelos de Kendall

$M/M/1$ representa llegadas Poisson, servicios exponenciales y un servidor. Si no se especifica, se suponen capacidad y población infinitas.

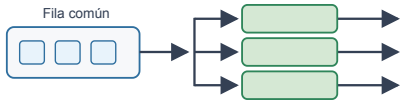
$M/M/1/K$ limita el número total de solicitudes. Con $K = 4$, una recibe servicio y hasta tres esperan.

$M/M/c$ tiene c servidores en paralelo y una fila común. La tasa μ corresponde a cada servidor.

La abreviatura resume supuestos que deben coincidir con el proceso real.

Modelos de sistemas de atención

Los modelos cambian en número de servidores y límite de solicitudes admitidas.

Modelo	Esquema	Qué permite estudiar
$M/M/1$		Un servidor y espera ilimitada. Permite estudiar utilización, número medio y tiempo de respuesta.
$M/M/1/K$		K limita el total, incluida la solicitud atendida. Si se llena, rechaza llegadas. Permite estudiar bloqueo y pérdidas.
$M/M/c$		Una fila común alimenta c servidores. Si todos están ocupados, hay espera. Permite estudiar el efecto de agregar servidores.

Proceso Poisson en sistemas de atención

Las solicitudes llegan de forma independiente y a una tasa media constante λ. Sea $N_A(t)$ el número de llegadas durante un intervalo de duración t. Para $k = 0, 1, 2, \ldots$, $k!$ indica el factorial de k:

$$P(N_A(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \qquad k = 0, 1, 2, \ldots$$

Con $\lambda = 6\ \text{solicitudes}\,\text{min}^{-1}$, la probabilidad de recibir exactamente dos solicitudes en un minuto es:

$$P(N_A(1\ \text{min}) = 2) = \frac{6^2 e^{-6}}{2!} \approx 0.0446.$$

Tiempos entre llegadas en sistemas de atención

Si las llegadas siguen un proceso de Poisson, los tiempos T entre llegadas consecutivas son independientes y exponenciales. Para un umbral temporal t, la cola de T y su media $E[T]$ son:

$$P(T > t) = e^{-\lambda t}, \qquad E[T] = \frac{1}{\lambda}.$$

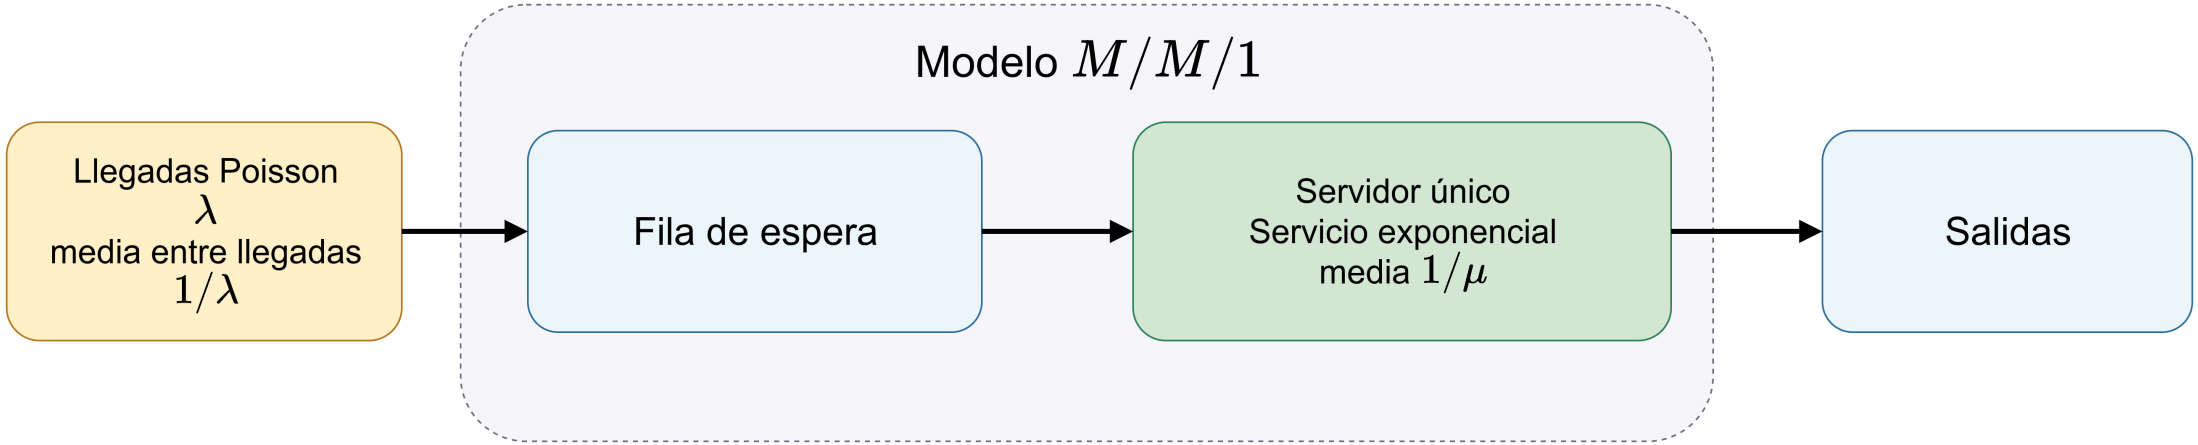
Con $\lambda = 6\ \mathrm{min}^{-1}$, el tiempo medio es $1/6\ \mathrm{min} = 10\ \mathrm{s}$.

La distribución exponencial no tiene memoria. Para una espera previa s y un periodo adicional t:

$$P(T > s + t \mid T > s) = P(T > t).$$

Haber esperado s sin una llegada no cambia la distribución del tiempo restante.

Poisson y servicio en $M/M/1$



La primera M indica llegadas Poisson, con tiempos entre llegadas exponenciales de media $1/\lambda$. La segunda M indica tiempos de servicio exponenciales de media $1/\mu$. El 1 representa un servidor. Las llegadas y los tiempos de servicio se suponen independientes.

Ley de Little

Conocemos el número medio de solicitudes presentes y cuántas se completan por segundo. ¿Cuánto permanece cada solicitud?

En régimen estable, la Ley de Little relaciona estas medidas:

$$L = \lambda_{\mathrm{e}} W$$

L cuenta las solicitudes en el sistema. W es su tiempo medio desde la admisión hasta la salida y λ_{e} la tasa efectiva admitida.

Para esas mismas solicitudes mientras esperan:

$$L_q = \lambda_{\mathrm{e}} W_q$$

L_q cuenta las solicitudes en espera y W_q es su tiempo medio de espera.

> No requiere distribuciones exponenciales. Use la misma población y frontera.

¿De dónde sale la Ley de Little?

Más solicitudes completadas por segundo o más tiempo de permanencia implican más solicitudes presentes. Si se completan $10\ \text{solicitudes}\,\text{s}^{-1}$ y cada una permanece $2\ \text{s}$, hay 20 solicitudes en promedio:

$$(10\ \text{solicitudes}\,\text{s}^{-1})(2\ \text{s}) = 20\ \text{solicitudes}.$$

El producto de la tasa por el tiempo de permanencia da el número medio de solicitudes presentes.

El área bajo $N(t)$

En cada instante t, $N(t)$ cuenta las solicitudes en el sistema. El área $\int_0^T N(t)\,\mathrm{d}t$ suma su tiempo total de permanencia durante una observación de duración T.

En una observación larga, el efecto de sus extremos es pequeño. El tiempo acumulado se aproxima a $C(T)W$, donde $C(T)$ es el número de solicitudes completadas. Como $C(T)/T$ se aproxima a λ_e:

$$L = \lim_{T\to\infty} \frac{1}{T}\int_0^T N(t)\,\mathrm{d}t = \lim_{T\to\infty} \frac{C(T)}{T} W = \lambda_\mathrm{e} W.$$

Ejemplo Ley de Little

Una interfaz de programación de aplicaciones (API) completa 120 solicitudes por segundo y se observan, en promedio, 18 solicitudes dentro del sistema.

$$W = \frac{L}{\lambda_{\mathrm{e}}} = \frac{18}{120\ \mathrm{s}^{-1}} = 0.15\ \mathrm{s}$$

Si $L_q = 12$:

$$W_q = \frac{12}{120\ \mathrm{s}^{-1}} = 0.10\ \mathrm{s}$$

Por diferencia, el tiempo medio en servicio es $0.05\ \mathrm{s}$.