TEL211

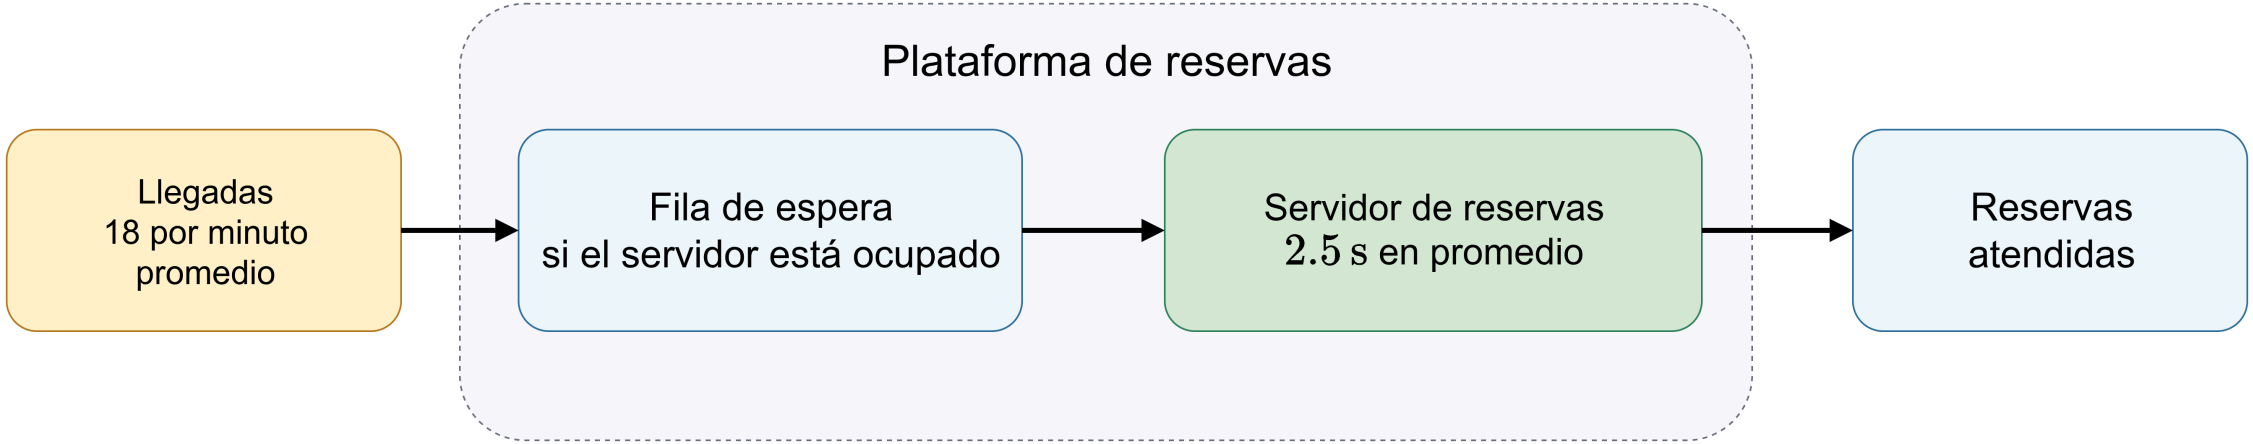
Disponibilidad y Rendimiento de Sistemas de Tecnologías de Información y Comunicaciones (TIC)

Teoría de filas: de la carga al tiempo de respuesta

Patricio Olivares R.
Universidad Técnica Federico Santa María

Un servicio puede estar disponible y responder tarde

En hora punta llegan $18\ \text{solicitudes}\,\text{min}^{-1}$ a una plataforma de reservas. Un servidor tarda, en promedio, $2.5\ \text{s}$ en atender cada solicitud.



Si el servidor está ocupado, la nueva solicitud espera. El servicio sigue disponible, pero la disponibilidad no indica cuánto demora cada respuesta.

¿Qué estudia la teoría de filas?

La teoría de filas estudia sistemas donde solicitudes llegan, esperan si los servidores están ocupados, reciben servicio y salen. Si no queda espacio, se rechazan.

Un modelo describe las llegadas, el espacio de espera, la capacidad de servicio y el orden de atención. Así permite estimar tiempos de respuesta, solicitudes acumuladas, utilización y bloqueo.

Qué observaremos bajo carga

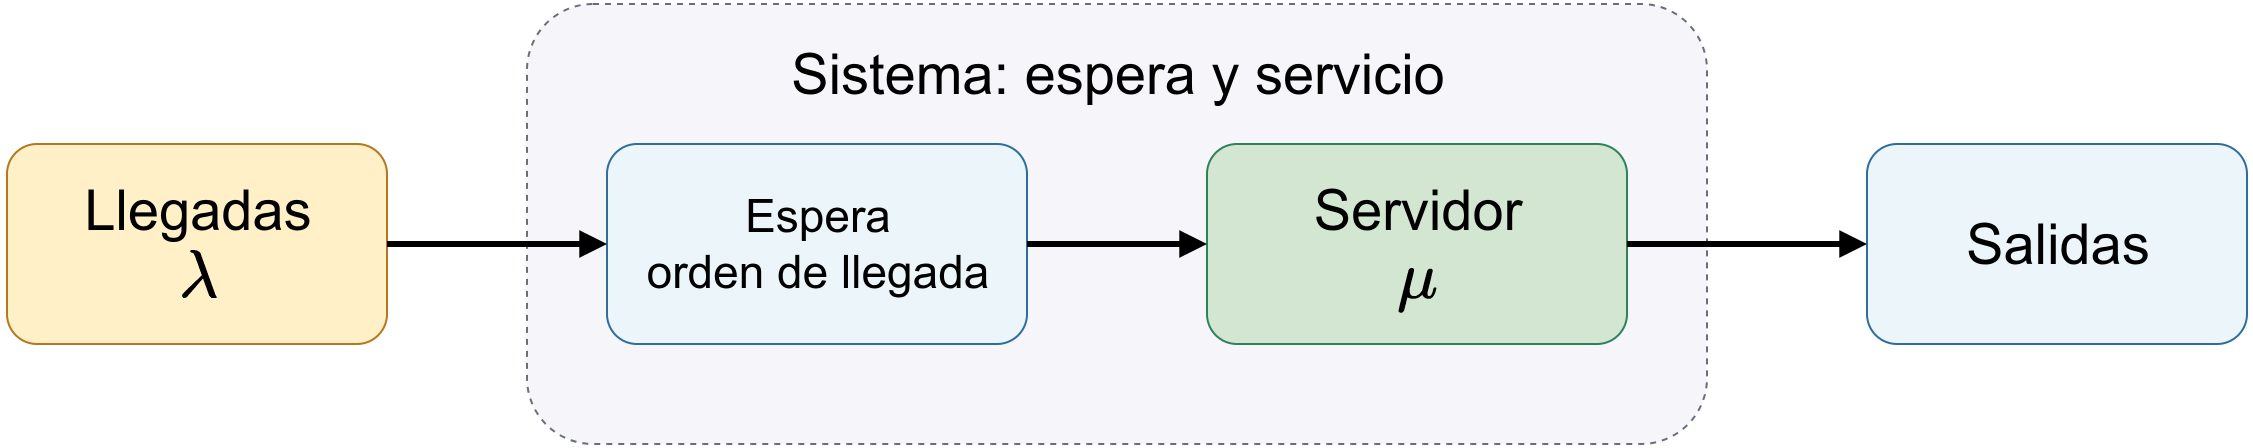
Pregunta	Medida
¿Cuánto tarda una solicitud, en promedio?	W (*waiting*): desde la admisión hasta la salida. W_q: solo la espera.
¿Cuántas solicitudes hay, en promedio?	L (*line*): en todo el sistema. L_q: solo en espera.
¿Qué fracción del tiempo está ocupado el servidor?	Utilización ρ
¿Qué probabilidad hay de rechazar una llegada?	Bloqueo P_{B} y tasa efectiva λ_{e}
¿Cuántos servidores satisfacen el objetivo?	Capacidad y latencia para un SLA

Magnitudes y frontera

Magnitud	Significado	Unidad típica
λ	tasa de llegada ofrecida	$\text{solicitudes}\,\text{s}^{-1}$
λ_{e}	tasa efectiva admitida	$\text{solicitudes}\,\text{s}^{-1}$
μ	tasa de servicio por servidor	$\text{solicitudes}\,\text{s}^{-1}$
L, L_q	número medio en sistema y en espera	solicitudes
W, W_q	tiempo medio en sistema y en espera	s
ρ	utilización: fracción de capacidad ocupada	adimensional
P_{B}	probabilidad de bloqueo	adimensional

Un acuerdo de nivel de servicio (SLA) fija el objetivo de latencia, bloqueo u otra métrica que se debe satisfacer.

Anatomía de una fila



La frontera del sistema incluye a quienes esperan y a quienes están en servicio. Una llegada puede entrar o ser rechazada si no queda espacio.

El tiempo de respuesta va desde la admisión hasta la salida. El tiempo de espera termina cuando comienza el servicio.

Llegadas y servicio en Kendall

A viene de *Arrival* y describe los tiempos entre llegadas. S viene de *Service* y describe los tiempos de servicio. Cada campo puede tomar uno de estos valores:

Valor	Significado
M	*Markovian*. La exponencial no tiene memoria. En A corresponde a llegadas Poisson y en S a servicio exponencial.
D	*Deterministic*. El tiempo entre llegadas o el tiempo de servicio es fijo.
G	*General*. Se permite otra distribución de probabilidad.

Servidores, capacidad, población y disciplina

Los campos restantes describen los recursos y las reglas del sistema:

Campo	Significado
c	Número de servidores en paralelo.
K	Capacidad máxima dentro del sistema, incluido quien recibe servicio.
N	*Number* de fuentes posibles de solicitudes.
D	*Discipline*, regla que decide quién sigue. FCFS (*First Come, First Served*) atiende en orden de llegada.

En los campos A o S, D significa *Deterministic*. Como último campo, D significa *Discipline*.

Notación

Los seis campos aparecen en este orden: $A/S/c/K/N/D$. El símbolo ∞ indica que la capacidad o la población no tienen límite.

Por ejemplo, $M/M/2/10/\infty/\mathrm{FCFS}$ describe llegadas Poisson, servicio exponencial, dos servidores, capacidad total de diez, población ilimitada y atención en orden de llegada.

Aquí $N(t)$ representa el número de solicitudes dentro del sistema en el instante t. En Kendall, N representa la población fuente.

Ejemplos de modelos de Kendall

$M/M/1$ representa llegadas Poisson, servicios exponenciales y un servidor. Si no se especifica, se suponen capacidad y población infinitas.

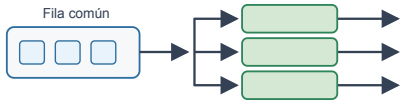
$M/M/1/K$ limita el número total de solicitudes. Con $K = 4$, una recibe servicio y hasta tres esperan.

$M/M/c$ tiene c servidores en paralelo y una fila común. La tasa μ corresponde a cada servidor.

La abreviatura resume supuestos que deben coincidir con el proceso real.

Modelos de sistemas de atención

Los modelos cambian en número de servidores y límite de solicitudes admitidas.

Modelo	Esquema	Qué permite estudiar
$M/M/1$		Un servidor y espera ilimitada. Permite estudiar utilización, número medio y tiempo de respuesta.
$M/M/1/K$		K limita el total, incluida la solicitud atendida. Si se llena, rechaza llegadas. Permite estudiar bloqueo y pérdidas.
$M/M/c$		Una fila común alimenta c servidores. Si todos están ocupados, hay espera. Permite estudiar el efecto de agregar servidores.

Proceso Poisson en sistemas de atención

Las solicitudes llegan de forma independiente y a una tasa media constante λ. Sea $N_A(t)$ el número de llegadas durante un intervalo de duración t. Para $k = 0, 1, 2, \ldots$, $k!$ indica el factorial de k:

$$P(N_A(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \qquad k = 0, 1, 2, \ldots$$

Con $\lambda = 6\ \text{solicitudes}\,\text{min}^{-1}$, la probabilidad de recibir exactamente dos solicitudes en un minuto es:

$$P(N_A(1\ \text{min}) = 2) = \frac{6^2 e^{-6}}{2!} \approx 0.0446.$$

Tiempos entre llegadas en sistemas de atención

Si las llegadas siguen un proceso de Poisson, los tiempos T entre llegadas consecutivas son independientes y exponenciales. Para un umbral temporal t, la cola de T y su media $E[T]$ son:

$$P(T > t) = e^{-\lambda t}, \qquad E[T] = \frac{1}{\lambda}.$$

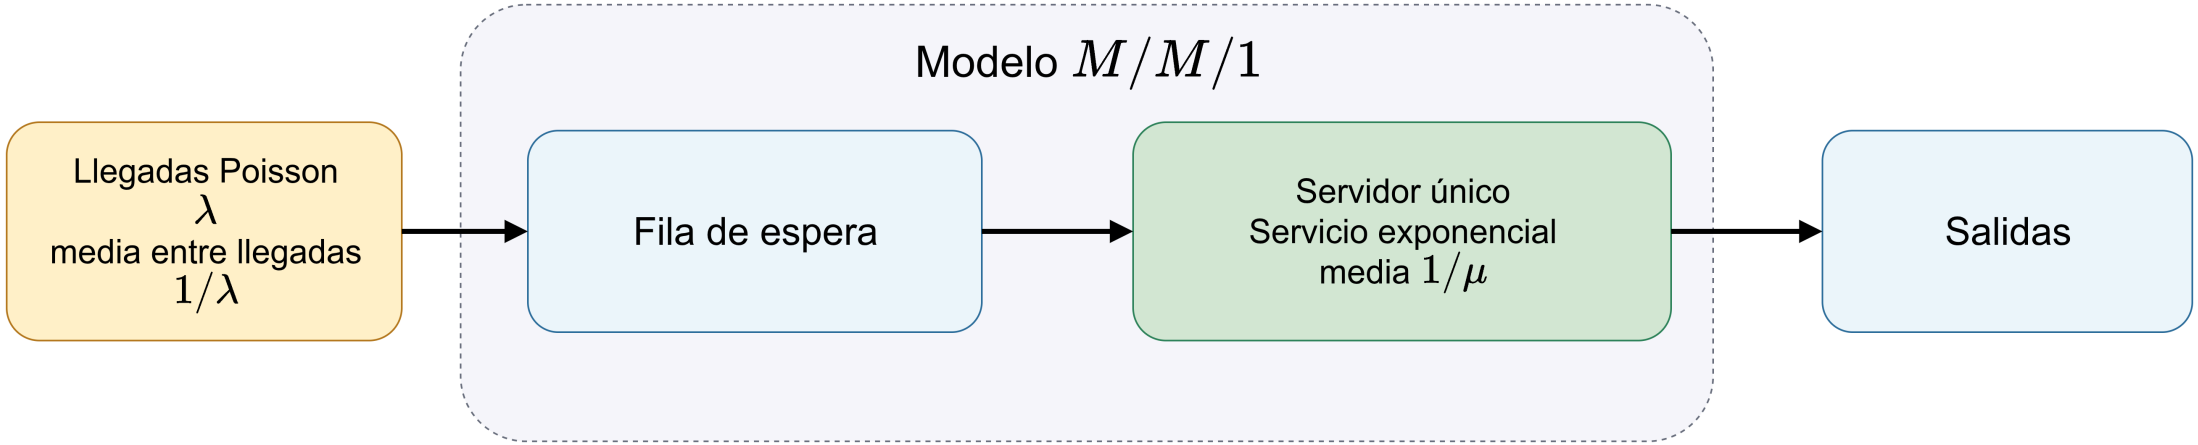
Con $\lambda = 6\ \mathrm{min}^{-1}$, el tiempo medio es $1/6\ \mathrm{min} = 10\ \mathrm{s}$.

La distribución exponencial no tiene memoria. Para una espera previa s y un periodo adicional t:

$$P(T > s + t \mid T > s) = P(T > t).$$

Haber esperado s sin una llegada no cambia la distribución del tiempo restante.

Poisson y servicio en $M/M/1$



La primera M indica llegadas Poisson, con tiempos entre llegadas exponenciales de media $1/\lambda$. La segunda M indica tiempos de servicio exponenciales de media $1/\mu$. El 1 representa un servidor. Las llegadas y los tiempos de servicio se suponen independientes.

Ley de Little

Conocemos el número medio de solicitudes presentes y cuántas se completan por segundo. ¿Cuánto permanece cada solicitud?

En régimen estable, la Ley de Little relaciona estas medidas:

$$L = \lambda_{\mathrm{e}} W$$

L cuenta las solicitudes en el sistema. W es su tiempo medio desde la admisión hasta la salida y λ_{e} la tasa efectiva admitida.

Para esas mismas solicitudes mientras esperan:

$$L_q = \lambda_{\mathrm{e}} W_q$$

L_q cuenta las solicitudes en espera y W_q es su tiempo medio de espera.

> No requiere distribuciones exponenciales. Use la misma población y frontera.

¿De dónde sale la Ley de Little?

Más solicitudes completadas por segundo o más tiempo de permanencia implican más solicitudes presentes. Si se completan $10\ \text{solicitudes}\,\text{s}^{-1}$ y cada una permanece $2\ \text{s}$, hay 20 solicitudes en promedio:

$$(10\ \text{solicitudes}\,\text{s}^{-1})(2\ \text{s}) = 20\ \text{solicitudes}.$$

El producto de la tasa por el tiempo de permanencia da el número medio de solicitudes presentes.

El área bajo $N(t)$

En cada instante t, $N(t)$ cuenta las solicitudes en el sistema. El área $\int_0^T N(t)\,\mathrm{d}t$ suma su tiempo total de permanencia durante una observación de duración T.

En una observación larga, el efecto de sus extremos es pequeño. El tiempo acumulado se aproxima a $C(T)W$, donde $C(T)$ es el número de solicitudes completadas. Como $C(T)/T$ se aproxima a λ_e:

$$L = \lim_{T\to\infty} \frac{1}{T}\int_0^T N(t)\,\mathrm{d}t = \lim_{T\to\infty} \frac{C(T)}{T} W = \lambda_\mathrm{e} W.$$

Ejemplo Ley de Little

Una interfaz de programación de aplicaciones (API) completa 120 solicitudes por segundo y se observan, en promedio, 18 solicitudes dentro del sistema.

$$W = \frac{L}{\lambda_{\mathrm{e}}} = \frac{18}{120\ \mathrm{s}^{-1}} = 0.15\ \mathrm{s}$$

Si $L_q = 12$:

$$W_q = \frac{12}{120\ \mathrm{s}^{-1}} = 0.10\ \mathrm{s}$$

Por diferencia, el tiempo medio en servicio es $0.05\ \mathrm{s}$.

Espera y servicio

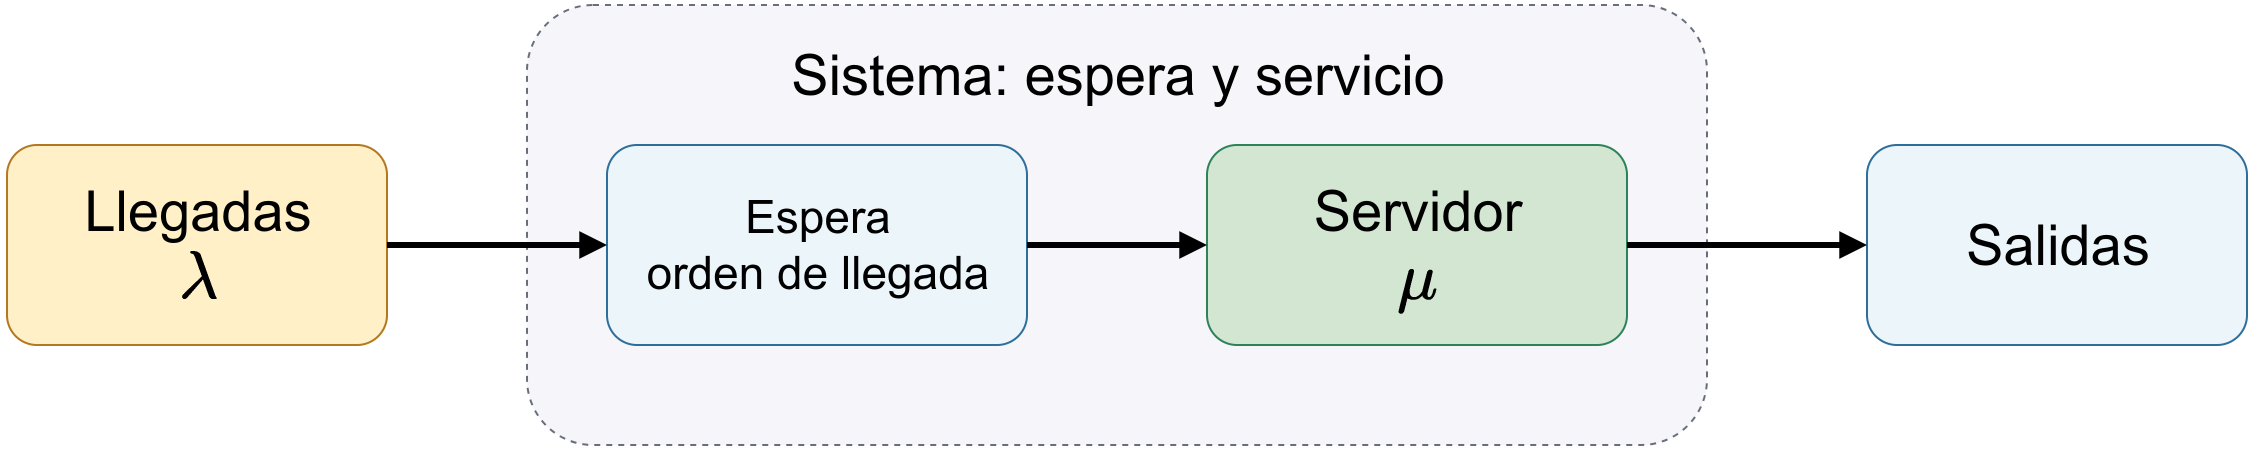
El tiempo medio de respuesta se descompone en el tiempo medio de espera y el tiempo medio de servicio. Si cada solicitud admitida recibe un servicio que dura, en promedio, $1/\mu$:

$$W = W_q + \frac{1}{\mu}.$$

En el ejemplo, $0.15\ \mathrm{s} = 0.10\ \mathrm{s} + 0.05\ \mathrm{s}$. Esta igualdad descompone el tiempo de respuesta. No es la Ley de Little.

Modelo $M/M/1$

En $M/M/1$, las solicitudes llegan al azar, pueden esperar si el servidor está ocupado y son atendidas por un único servidor.



Las llegadas siguen un proceso de Poisson con tasa λ. Los tiempos de servicio son exponenciales con tasa μ. El servidor atiende en orden de llegada.

Se suponen capacidad de espera y población fuente ilimitadas. El proceso de llegadas y los tiempos de servicio son independientes.

Utilización y estabilidad

λ es el número medio de solicitudes que llegan por unidad de tiempo. μ es el número que un servidor ocupado puede atender por unidad de tiempo.

La utilización es:

$$\rho = \frac{\lambda}{\mu}.$$

En régimen estacionario, ρ es la fracción del tiempo que el servidor está ocupado. Los tres casos son:

Condición	Comportamiento
$\lambda < \mu$	Estable. Existe régimen estacionario con un número medio finito de solicitudes.
$\lambda = \mu$	Límite de estabilidad. No hay distribución estacionaria.
$\lambda > \mu$	Sobrecarga. La fila crece sin límite a largo plazo.

Cuando la llegada supera el servicio

Si llegan $12\ \text{solicitudes}\,\text{min}^{-1}$ y el servidor puede atender $10\ \text{solicitudes}\,\text{min}^{-1}$:

$$\lambda = 12, \qquad \mu = 10, \qquad \rho = \frac{12}{10} = 1.2.$$

El valor $\rho = 1.2$ no significa que el servidor esté ocupado el 120% del tiempo. Fuera del régimen estable, ρ compara la carga ofrecida con la capacidad.

La tasa de llegada supera la capacidad en dos solicitudes por minuto. A largo plazo, la acumulación crece aproximadamente a ese ritmo.

Las fórmulas estacionarias de $M/M/1$ solo se aplican bajo esta condición:

$$\boxed{\lambda < \mu \quad \Longleftrightarrow \quad \rho < 1}.$$

Incluso en este régimen, la variabilidad puede formar filas.

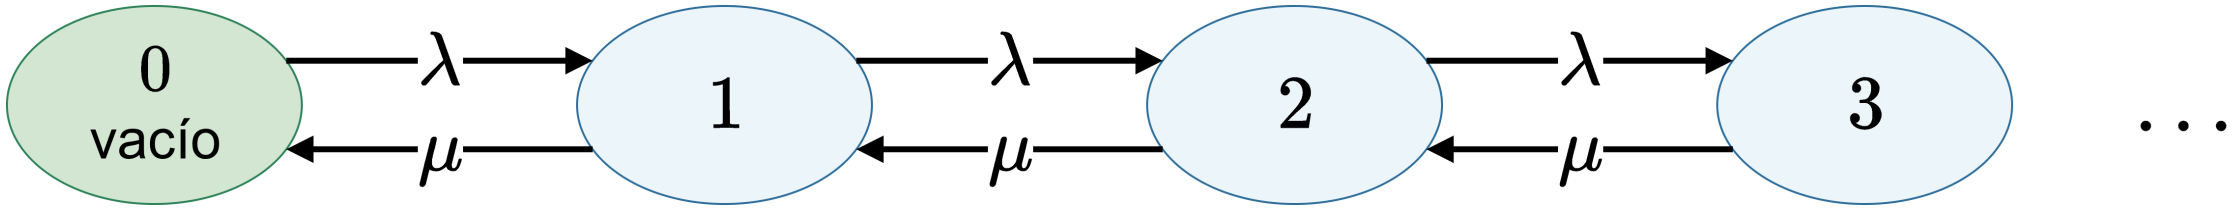
¿Por qué se forma una fila si $\lambda < \mu$?

Aunque la llegada media sea menor que la capacidad, algunas solicitudes pueden coincidir mientras el servidor está ocupado. Para seguir la acumulación usamos el estado

$$N(t) = \text{número de solicitudes dentro del sistema.}$$

Con servicio exponencial, basta conocer cuántas solicitudes hay. Otras distribuciones pueden exigir más información sobre el servicio en curso.

$M/M/1$ como proceso de nacimiento y muerte



El estado n cuenta las solicitudes en el sistema. El proceso cambia el estado de uno en uno. Cada llegada es un nacimiento y cada servicio completado es una muerte.

$$n \to n+1 \text{ a tasa } \lambda$$

$$n \to n-1 \text{ a tasa } \mu, \qquad n \geq 1$$

Distribución estacionaria de $M/M/1$

Sea π_n la probabilidad estacionaria de tener n solicitudes. π_0 corresponde al sistema vacío.

En equilibrio se igualan los flujos vecinos. Cada flujo es la probabilidad del estado de origen por su tasa de transición:

$$\pi_n \lambda = \pi_{n+1} \mu \quad \Longrightarrow \quad \pi_n = \rho^n \pi_0.$$

Al normalizar, la serie geométrica converge si $\rho < 1$:

$$1 = \sum_{n=0}^{\infty} \pi_n = \pi_0 \sum_{n=0}^{\infty} \rho^n = \frac{\pi_0}{1-\rho} \quad \Longrightarrow \quad \pi_0 = 1-\rho, \qquad \pi_n = (1-\rho)\rho^n.$$

La suma es una serie geométrica infinita: $\sum_{n=0}^{\infty} \rho^n = \frac{1}{1-\rho}$, válida para $0 \leq \rho < 1$. Ver serie geométrica.

Interpretar la estabilidad

La serie geométrica converge solo si $\rho < 1$. En $M/M/1$, esta condición permite normalizar la distribución estacionaria.

Si $\lambda = \mu$, no hay régimen estacionario con promedios finitos. Si $\lambda > \mu$, la carga supera la capacidad.

En ambos casos fallan las fórmulas estacionarias de $M/M/1$. Se puede reducir llegadas, aumentar el servicio o agregar servidores. Limitar la capacidad evita una fila infinita, pero causa pérdidas.

Obtener el número medio en el sistema

Con $\pi_n = (1-\rho)\rho^n$:

$$L = \sum_{n=0}^{\infty} n\pi_n = (1-\rho)\sum_{n=0}^{\infty} n\rho^n.$$

Esta suma es un caso de una serie aritmético-geométrica:

$$\sum_{n=0}^{\infty} n\rho^n = \frac{\rho}{(1-\rho)^2}.$$

Por tanto:

$$L = \frac{\rho}{1-\rho}.$$

Número medio en espera

Sea N el número de solicitudes en el sistema y Q el número esperando. Como hay un solo servidor:

$$Q = N - \mathbf{1}_{\{N \geq 1\}},$$

con el indicador igual a uno si el servidor está ocupado y cero si está libre. En régimen estacionario:

$$L_q = \mathbb{E}[Q] = \mathbb{E}[N] - \mathbb{P}(N \geq 1) = L - \mathbb{P}(\text{servidor ocupado}).$$

En $M/M/1$, $\pi_0 = 1 - \rho$, por lo que:

$$\mathbb{P}(N \geq 1) = 1 - \pi_0 = \rho,$$

Por tanto, el número medio total se descompone en solicitudes en espera y en servicio. Como hay un solo servidor, el número medio en servicio es ρ:

$$L = L_q + \rho \quad \Longrightarrow \quad L_q = L - \rho.$$

Métricas de $M/M/1$

> Estas fórmulas describen promedios estacionarios y se aplican cuando $\rho < 1$.

Número medio de solicitudes

L cuenta las solicitudes en espera y en servicio. L_q cuenta solo las que esperan. Como se explicó antes, $L_q = L - \rho$.

$$L = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda},$$

$$L_q = \frac{\rho^2}{1-\rho} = \frac{\lambda^2}{\mu(\mu-\lambda)}.$$

Tiempo medio de permanencia

W mide el tiempo desde que una solicitud llega hasta que sale. W_q mide solo el tiempo que espera en la fila. Como la cola es ilimitada, todas las llegadas entran al sistema y la tasa efectiva es λ. Por la ley de Little, $L = \lambda W$ y $L_q = \lambda W_q$.

$$W = \frac{L}{\lambda} = \frac{1}{\mu - \lambda},$$

$$W_q = \frac{L_q}{\lambda} = \frac{\lambda}{\mu(\mu-\lambda)} = \frac{\rho}{\mu - \lambda}.$$

Por qué la latencia crece tan rápido

$$W = \frac{1}{\mu(1-\rho)}$$

El tiempo medio de servicio es $1/\mu$. La siguiente tabla expresa el tiempo total de permanencia W como múltiplo de ese tiempo $\frac{W}{1/\mu} = \frac{1}{1-\rho}$.

ρ	W/(1/μ)
0.50	2 veces
0.80	5 veces
0.90	10 veces
0.95	20 veces

Por qué la latencia crece tan rápido

Por ejemplo, con $\rho = 0.95$, el tiempo medio total es 20 veces el tiempo de servicio. De ese total, 19 veces corresponden a la espera en la fila, pues $W_q = W - 1/\mu$. El servicio no se vuelve más lento. El aumento se debe a la espera.

> El modelo es estable cuando $\rho < 1$. Al acercarse ρ a 1, el factor $1/(1-\rho)$ crece rápidamente y queda menos margen para variaciones en la carga.

Ejemplo $M/M/1$: puerta de enlace

Considere una puerta de enlace que recibe solicitudes y las envía a un único servidor.

Modele las llegadas como un proceso de Poisson y los tiempos de servicio como exponenciales e independientes. Suponga que $\lambda = 125\ \text{solicitudes}/\text{s}$ y que el tiempo medio de servicio es $1/\mu = 2\ \text{ms}$.

Preguntas

1. Calcule la tasa media de servicio μ y la utilización ρ. Determine si el sistema es estable.
2. Calcule el tiempo medio de permanencia W y el tiempo medio de espera W_q.
3. Calcule el número medio de solicitudes en el sistema L y en la fila L_q. Interprete los resultados.

Ejemplo $M/M/1$: respuestas

Tasa media de servicio

$$\mu = \frac{1}{\mathbb{E}[S]} = \frac{1}{2\ \text{ms}} = 500\ \text{solicitudes/s}.$$

Utilización y estabilidad

$$\rho = \frac{\lambda}{\mu} = \frac{125}{500} = 0.25 < 1.$$

El sistema es estable porque $\rho < 1$.

Ejemplo $M/M/1$: respuestas de tiempo

W mide el tiempo desde la llegada hasta la salida. W_q mide solo la espera en la fila.

Permanencia media en el sistema

$$W = \frac{1}{\mu - \lambda} = \frac{1}{500 - 125}\ \mathrm{s} = 2.667\ \mathrm{ms}.$$

Espera media en la fila

$$W_q = \frac{\lambda}{\mu(\mu - \lambda)} = \frac{125}{500(500 - 125)}\ \mathrm{s} = 0.667\ \mathrm{ms}.$$

Ejemplo $M/M/1$: respuestas de cantidad

Por la ley de Little, $L = \lambda W$ y $L_q = \lambda W_q$:

$$L = \lambda W = (125 \text{ solicitudes/s})(0.002667 \text{ s}) = 0.333 \text{ solicitudes},$$
$$L_q = \lambda W_q = (125 \text{ solicitudes/s})(0.000667 \text{ s}) = 0.083 \text{ solicitudes}.$$

En promedio, cada solicitud permanece 2.667 ms en el sistema, incluidos 0.667 ms de espera y 2 ms de servicio. L y L_q son promedios temporales, por eso pueden ser menores que una solicitud.